دانشگاه تربیت مدرس

دانشکده علوم ریاضی

# پایان‌نامه دوره کارشناسی ارشد علوم کامپیوتر

# روش های عمیق مبتنی برمبدل های بینایی در تحلیل داده های تصویری

توسط

سید محمد بادزهره

استاد راهنما

آقای دکتر منصور رزقی

پاییز ۱۴۰۳

تقدیم به

پدر بزرگوار و مادر مهربانم و برادر عزیزم

آن ها که از خواسته هایشان گذشتند، سختی ها را به جان خریدند و خود را سپر بلای مشکلات و ناملایمات کردند تا من به جایگاهی که اکنون در آن ایستاده ام برسم .

## قدردانی

از استاد گرانقدر، جناب آقای دکتر رزقی که با راهنمایی های دلسوزانه و ارزشمند خود، همواره در مسیر تحقیق این پایان نامه یار و راهنمای من بودند، نهایت سپاس و قدردانی را دارم.

از خانواده عزیزم که با محبت بی پایان، صبوری و حمایت های بی دریغ شان، همواره پشتیبان من در طی این مسیر سخت و پرچالش بودند، صمیمانه سپاسگزارم.

سید محمد بادزهره

پاییز ۱۴۰۳

# چکیده

ببعلعذدقفلهعقفدلخقفدللقفلقفاقا

# فهرست مطالب


فهرست جداول ۵

فهرست تصاویر و

پیش‌گفتار ۱

۱ مفاهیم اولیه ۲

۱.۱ مقدمه . . . . . ۲

۲ مفاهیم اولیه ۳

۱.۲ مقدمه . . . . . ۳

۱.۱.۲ آغاز هوش مصنوعی و هدف اصلی . . . . . ۳

۲.۱.۲ دورهٔ طلایی و پیشرفت‌های اولیه . . . . . ۴

۳.۱.۲ انتظارات بیش از حد و ظهور عصر تاریک . . . . . ۴

۴.۱.۲ عوامل اصلی عصر تاریک هوش مصنوعی . . . . . ۵

۵.۱.۲ پایان عصر تاریک و بازگشت هوش مصنوعی . . . . . ۵

۲.۲ انواع مدل یادگیری ماشین و شبکه‌های عصبی . . . . . ۶

۱.۲.۲ یادگیری ماشین: مروری کلی . . . . . ۶

۲.۲.۲ تقسیم‌بندی‌های اصلی در یادگیری ماشین . . . . . ۷

۳.۲.۲ یادگیری نظارت‌شده . . . . . ۷
۴.۲.۲ یادگیری تقویتی . . . . . ۸
۵.۲.۲ معرفی چند مدل از الگوریتم یادگیری کلاسیک . . . . . ۹
۶.۲.۲ ماشین بردار پشتیبان . . . . . ۱۰
۷.۲.۲ بیز ساده . . . . . ۱۱
۸.۲.۲ شبکه‌های عصبی بازگشتی و شبکه‌های حافظه بلندمدت کوتاه‌مدت . . ۱۲
۹.۲.۲ شبکه‌های عصبی بازگشتی . . . . . ۱۲
۱۰.۲.۲ مزایا و معایب شبکه‌های عصبی بازگشتی . . . . . ۱۳
۱۱.۲.۲ شبکه‌های حافظه بلندمدت_ کوتاه‌مدت . . . . . ۱۴
۱۲.۲.۲ ظهور شبکه‌های حافظهٔ بلندمدت_ کوتاه‌مدت . . . . . ۱۵
۳.۲ ساختار شبکه های حافظه بلند_ مدت کوتاه_ مدت . . . . . ۱۶
۱.۳.۲ وضعیت سلولی . . . . . ۱۶
۲.۳.۲ دروازه‌ها . . . . . ۱۷
۳.۳.۲ به‌روزرسانی وضعیت سلولی . . . . . ۱۸
۴.۳.۲ مشکلات کلی شبکه های بازگشتی و ظهور مبدل ها . . . . . ۱۹

۳ پیشینه پژوهش ۲۳
۱.۳ مقدمه . . . . . ۲۳
۲.۳ مشکلات ترجمه ماشینی و مبدل ها . . . . . ۲۳
۳.۳ ظهور ترانسفورمرها . . . . . ۲۴
۴.۳ معماری ترانسفورمرها . . . . . ۲۵
۱.۴.۳ جاسازی . . . . . ۲۵
۲.۴.۳ جاسازی موقعیتی . . . . . ۲۶

۳.۴.۳ توجه . . . . . ۲۸
۴.۴.۳ اتصال باقی مانده . . . . . ۳۲
۵.۴.۳ مزایای اتصال باقی مانده در ترانسفورمر . . . . . ۳۳
۵.۳ نرمال سازی لایه ها . . . . . ۳۴
۶.۳ رمزگشا . . . . . ۳۶
۷.۳ توجه چند سری ماسک شده . . . . . ۳۸
۸.۳ مثال عددی توجه ماسک شده . . . . . ۳۸
۹.۳ مبدل های بینایی . . . . . ۳۹
۱.۹.۳ . . . . . ۴۰
۲.۹.۳ شکل پچ‌ها: . . . . . ۴۰
۳.۹.۳ تعداد پچ‌ها: . . . . . ۴۱
۴.۹.۳ بردارکردن هر پچ . . . . . ۴۳
۱۰.۳ اعمال لایهٔ خطی . . . . . ۴۳
۱.۱۰.۳ توکن کلاس بندی . . . . . ۴۵
۲.۱۰.۳ انکودر در مبدل های بینایی . . . . . ۴۶
۱۱.۳ مبدل پنجره‌ای متحرک . . . . . ۴۷
۱.۱۱.۳ قطعه‌بندی پچ . . . . . ۴۸
۲.۱۱.۳ جاسازی . . . . . ۴۹
۳.۱۱.۳ توجه چند سر پنجره ای . . . . . ۵۰
۴.۱۱.۳ توجه . . . . . ۵۱
۵.۱۱.۳ پنجره متحرک . . . . . ۵۲
۶.۱۱.۳ پرسپتروون چند لایه . . . . . ۵۵
۷.۱۱.۳ ترکیب پچ ها . . . . . ۵۵

۴ پیشینه پژوهش ۵۹
۱.۰.۴ ویژگی‌های محلی (Local Features) . . . . . ۶۰
۲.۰.۴ ویژگی‌های جهانی (Global Features) . . . . . ۶۰
۳.۰.۴ ترانسفورمرها و محدودیت‌های دید محلی . . . . . ۶۱
۴.۰.۴ روش اول: . . . . . ۶۱
۵.۰.۴ تبدیل تصاویر به دو پچ مجزا: . . . . . ۶۱
۶.۰.۴ هماهنگ سازی پچ ها: . . . . . ۶۲
۷.۰.۴ Positional Embedding . . . . . ۶۶
۸.۰.۴ لایه های اول تا هشتم انکودر . . . . . ۶۷
۹.۰.۴ لایه نهم انکودر . . . . . ۶۷
۱۰.۰.۴ محاسبهٔ ماتریس شباهت ($QK^T$) و میانگین‌گیری . . . . . ۶۸
۱۱.۰.۴ اعمال مقیاس‌بندی $\frac{1}{\sqrt{d_k}}$ و Softmax . . . . . ۶۹
۱۲.۰.۴ ادغام وزنی . . . . . ۷۱
۱.۴ روش دوم sampling: down . . . . . ۷۱
۱.۱.۴ حرکت تدریجی از جزئیات به کلیت . . . . . ۷۳
۲.۱.۴ کم نشدن پارامتر ها در این مدل . . . . . ۷۴

۵ آزمایشات و نتایج ۷۶

کتاب‌نامه ۷۷

آ جزئیات مدل‌ها و جدول پارامترها ۸۲

# فهرست جداول

۲.۳.۱ مقایسه ویژگی‌های RNN و LSTM . . . . . ۱۹

# فهرست تصاویر


۲.۲.۱ RNN . . . . . ۱۲

۲.۳.۲ LSTM . . . . . ۱۷

۳.۴.۱ معماری ترانسفورمرها . . . . . ۲۶

۳.۴.۲ word embedding . . . . . ۲۷

۳.۴.۳ word embedding + positional embedding . . . . . ۲۸

۳.۴.۴ توجه . . . . . ۳۱

۳.۴.۵ multi head attention . . . . . ۳۲

۳.۶.۶ Decoder . . . . . ۳۷

۳.۹.۷ patch to image . . . . . ۴۰

۳.۹.۸ Image original . . . . . ۴۱

۳.۹.۹ paches of image . . . . . ۴۲

۱۰.۱۰ مبدل های بینایی . . . . . ۴۴

۱۰.۱۱ توکن توجه در مبدل های بینایی . . . . . ۴۶

۱۱.۱۲ مبدل پنجره متحرک . . . . . ۴۸

۱۱.۱۳ جا به جایی چرخه ای . . . . . ۵۴

۱۱.۱۴ ادغام پچ ها . . . . . ۵۸

# پیش‌گفتار

قدثثمقدکنقصدبثقلدقفخدلقخفادخفادخ

# فصل ۱

# مفاهیم اولیه

در این فصل به معرفی مقدمات و مفاهیم مورد نیاز در این پایان‌نامه می‌پردازیم.

## ۱.۱ مقدمه

در این بخش به تاریخچه هوش مصنوعی، دستاورد های اولیه، چالش ها، دلایل رکود هوش مصنوعی و پایان عصر تاریک هوش مصنوعی صحبت میکنیم

# فصل ۲

# مفاهیم اولیه

در این فصل به معرفی مقدمات و مفاهیم مورد نیاز در این پایان‌نامه می‌پردازیم.

## ۱.۲ مقدمه

در این بخش به تاریخچه هوش مصنوعی، دستاوردهای اولیه، چالش‌ها، دلایل رکود هوش مصنوعی و پایان عصر تاریک هوش مصنوعی صحبت می‌کنیم.

### ۱.۱.۲ آغاز هوش مصنوعی و هدف اصلی

هوش مصنوعی به عنوان شاخه‌ای از علوم کامپیوتر، در دهه ۱۹۵۰ با هدف ساخت سیستم‌ها و ماشین‌هایی که توانایی تقلید از هوش انسانی را دارند، آغاز شد. نخستین بار، مکارتی در سال ۱۹۵۶ این اصطلاح را به کار گرفت [۳۲] و هوش مصنوعی به عنوان علمی که در آن به مطالعه الگوریتم‌هایی برای تقلید رفتار انسانی می‌پردازد، شناخته شد. اهداف اولیه هوش مصنوعی شامل توانایی درک زبان، یادگیری، حل مسئله و تولید موجودات هوشمند بود. در این دوران پروژه‌های تحقیقاتی زیادی به

امید دستیابی به هوش مصنوعی عمومی (AGI, Artificial General Intelligence) شروع به کار کردند [۸، ۴۰].

### ۲.۱.۲ دورهٔ طلایی و پیشرفت‌های اولیه

در دههٔ ۵۰ و ۶۰ میلادی، هوش مصنوعی[۱] به عنوان یکی از پرچمداران پژوهش‌های نوین شناخته می‌شد. الگوریتم‌های اولیه با تکیه بر روش‌های منطقی و ریاضیاتی برای حل مسئله و بازی‌های ساده توسعه یافتند؛ مانند انواع الگوریتم‌های جستجوی درختی[۲] که در این دوره به وجود آمدند و زمینه‌ساز اولین دستاوردهای هوش مصنوعی در بازی‌های تخته‌ای[۳] همچون شطرنج[۴] شدند [۳۹].

در این دوران، پیشرفت‌های بیشتری در پردازش زبان طبیعی[۵] و سیستم‌های خبره[۶] نیز صورت گرفت که این امید را در دانشمندان و محققان تقویت کرد که دستیابی به هوش مصنوعی عمومی[۷] به‌زودی ممکن خواهد بود [۱۴].

### ۳.۱.۲ انتظارات بیش از حد و ظهور عصر تاریک

با وجود پیشرفت‌های هوش مصنوعی، محدودیت‌های تکنولوژی (مثل عدم وجود واحد پردازنده گرافیکی[۸]های پرقدرت در آن زمان) و همچنین کمبود داده‌های کافی برای آموزش مدل‌های پیچیده‌تر، باعث شد که بسیاری از پروژه‌های تحقیقاتی نتوانند به نتایج پیش‌بینی‌شده دست یابند. در نتیجه، هوش مصنوعی در دههٔ ۷۰ به مرحله‌ای از رکود وارد شد که به آن عصر تاریک هوش مصنوعی یا زمستان[۹] می‌گویند [۲۸، ۸]. در این دوران، بسیاری از پروژه‌ها تعطیل و سرمایه‌گذاری‌ها قطع شدند

[۱] Artificial Intelligence (AI)
[۲] Tree Search Algorithms
[۳] Board Games
[۴] Chess
[۵] Natural Language Processing (NLP)
[۶] Expert Systems
[۷] Artificial General Intelligence (AGI)
[۸] GPU
[۹] AI Winter

و دولت‌ها و سازمان‌های سرمایه‌گذار به دلیل عدم دستیابی به نتایج مطلوب از ادامهٔ سرمایه‌گذاری منصرف شدند.

### ۴.۱.۲ عوامل اصلی عصر تاریک هوش مصنوعی

- محدودیت‌های سخت‌افزاری: در آن زمان، سیستم‌های اولیهٔ هوش مصنوعی به محاسبات سنگینی نیاز داشتند که با توان پردازشی محدود آن دوره همخوانی نداشت [۴۰].
- کمبود داده‌ها: در آن زمان، دسترسی به داده‌های کافی برای آموزش مدل‌های پیچیده ممکن نبود و الگوریتم‌های موجود به داده‌های بیشتری نیاز داشتند تا بتوانند به‌درستی آموزش ببینند و عملکرد مطلوبی داشته باشند [۸].
- روش‌های محدود یادگیری: الگوریتم‌های اولیه به شدت به برنامه‌ریزی انسانی وابسته بودند و در بسیاری از موارد، مدل‌ها قادر به تعمیم به مسائل جدید نبودند و نمی‌توانستند تعمیم‌پذیری خیلی بالایی داشته باشند [۴۴].

### ۵.۱.۲ پایان عصر تاریک و بازگشت هوش مصنوعی

پس از چندین سال رکود و عدم سرمایه‌گذاری در حوزهٔ هوش مصنوعی، سرانجام در دههٔ ۱۹۸۰ و ۱۹۹۰ عصر تاریک هوش مصنوعی با تحولات تکنولوژی و از همه مهم‌تر ظهور سیستم‌های خبره به پایان رسید [۱۴]. سیستم‌های خبره به عنوان یکی از اولین تلاش‌های موفق برای کاربردهای صنعتی در هوش مصنوعی به‌وجود آمدند. بر خلاف الگوریتم‌های اولیه، این سیستم‌ها از پایگاه بزرگ قواعد و قوانین [۱۰] استفاده می‌کردند. در سیستم‌های خبره، به جای تلاش برای شبیه‌سازی کلی هوش مصنوعی، بر حل مسائل تخصصی برای صنایع و سازمان‌ها تمرکز می‌شد. برای مثال، سیستم‌های خبره در پزشکی برای تشخیص بیماری‌ها و پیشنهاد درمان، در صنعت برای مدیریت و پیش‌بینی خرابی ماشین‌آلات، و در امور مالی برای تحلیل و ارزیابی ریسک کاربرد داشتند [۳۳].

[۱۰] Rule Based Systems

هرچند این سیستم‌ها نمی‌توانستند درک عمیق و هوشمندی عمومی را ایجاد کنند، اما برای رفع نیازهای پیچیده مناسب بودند. همزمان با موفقیت این سیستم‌ها، بهبودهای زیادی در سخت‌افزارها و کاهش هزینه‌های پردازش به وجود آمد. در دهه‌های ۱۹۸۰ و ۱۹۹۰، کامپیوترها به تدریج قوی‌تر و مقرون به صرفه‌تر شدند و امکان پردازش داده‌های بیشتر و اجرای الگوریتم‌های پیچیده‌تر فراهم شد. این افزایش توان محاسباتی، نیاز به پردازش داده‌های بزرگ و پیچیده را برآورده کرد و در نتیجه دسترسی به داده‌ها و انجام محاسبات سنگین برای توسعهٔ الگوریتم‌های جدید تسهیل شد. از سوی دیگر، پیشرفت‌های انجام‌شده در ذخیره‌سازی داده و رشد اینترنت باعث دسترسی گسترده‌تر به داده‌ها و منابع اطلاعاتی گردید [۴۰].

به این ترتیب، مجموعه‌ای از عوامل، شامل ظهور سیستم‌های خبره، افزایش قدرت پردازش و دسترسی به داده‌های بیشتر، منجر به بازگشت هوش مصنوعی شد. این دوره نه تنها پایان عصر تاریک هوش مصنوعی بود، بلکه راه را برای الگوریتم‌های یادگیری ماشین و توسعهٔ شبکه‌های عصبی هموار کرد [۴۴].

## ۲.۲ انواع مدل یادگیری ماشین و شبکه‌های عصبی

یادگیری ماشین و شبکه‌های عصبی در سال‌های اخیر مورد توجه بسیاری قرار گرفته‌اند و در حوزه‌های متنوعی از جمله پردازش تصویر، پردازش زبان طبیعی و داده‌کاوی استفاده می‌شوند [۴، ۳۵، ۳۷].

### ۱.۲.۲ یادگیری ماشین: مروری کلی

یادگیری ماشین [۱۱] شاخه‌ای از هوش مصنوعی است که به مدل‌های محاسباتی این امکان را می‌دهد الگوها را از داده‌ها به شکل خودکار یاد بگیرند و بتوانند تصمیم‌گیری کنند [۱۶، ۳۵]. در واقع، هدف یادگیری ماشین این است که مدل‌ها بتوانند از داده‌ها الگوها و روابط پنهان را استخراج کنند و به نتایج و تصمیم‌های قابل اعتماد دست یابند.

[۱۱] Machine Learning

### ۲.۲.۲ تقسیم‌بندی‌های اصلی در یادگیری ماشین

به طور کلی، یادگیری ماشین به سه دستهٔ اصلی تقسیم می‌شود:

- یادگیری با نظارت[۱۲]
- یادگیری بدون نظارت[۱۳]
- یادگیری تقویتی[۱۴]

این طبقه‌بندی در بسیاری از کتاب‌ها و مراجع مهم یادگیری ماشین مطرح شده است [۴، ۳۷].

### ۳.۲.۲ یادگیری نظارت‌شده

یادگیری نظارت‌شده یکی از رایج‌ترین روش‌ها در یادگیری ماشین شناخته می‌شود که در آن از مجموعه داده‌های برچسب‌گذاری‌شده برای آموزش مدل استفاده می‌کنیم [۲۳]. هدف این الگوریتم تشخیص الگوها در میان داده‌های ورودی است تا بتواند روی داده‌های جدید پیش‌بینی یا طبقه‌بندی انجام دهد. این نوع شامل دو دسته الگوریتمِ رگرسیون [۱۵] و کلاس بندی[۱۶] می‌شود.

طبقه‌بندی

طبقه‌بندی یکی از مهم‌ترین و اصلی‌ترین وظایف در یادگیری نظارت‌شده است که هدف آن تخصیص هر داده به یک لیبل[۱۷] مشخص است [۴]. در این روش، مدل با داده‌های برچسب‌دار آموزش می‌بیند و یاد می‌گیرد که داده‌های جدید را بر اساس الگوها و ویژگی‌هایی که در داده‌های آموزشی دیده است،

[۱۲] Supervised Learning
[۱۳] Unsupervised Learning
[۱۴] Reinforcement Learning
[۱۵] Regression
[۱۶] Classification
[۱۷] Label

به دسته مناسب اختصاص دهد. از کاربردهای طبقه‌بندی می‌توان به تشخیص هرزنامه [۱۸] تشخیص بیماری (مثلاً آیا یک فرد مبتلا به بیماری هست یا نه) و تشخیص چهره اشاره کرد.

[۳۷].

رگرسیون

رگرسیون یکی از مهم‌ترین وظایف یادگیری ماشین است و هدف آن پیش‌بینی مقادیر پیوسته است [۳۶]. بر خلاف طبقه‌بندی که خروجی آن یک دسته‌بندی مجزا است، در رگرسیون خروجی یک مقدار پیوسته خواهد بود و مدل می‌آموزد روابط بین متغیرهای مستقل و متغیر هدف را شناسایی کند. از کاربردهای رگرسیون می‌توان به پیش‌بینی قیمت مسکن یا پیش‌بینی آب‌وهوا اشاره کرد.

### ۴.۲.۲ یادگیری تقویتی

یادگیری تقویتی، نوعی یادگیری بر پایهٔ پاداش و تنبیه است که در آن مدل با محیط تعامل می‌کند و بر اساس پاداش یا تنبیه یاد می‌گیرد [۴۶]. برخلاف یادگیری نظارت‌شده و بدون نظارت، یادگیری تقویتی به مدل این امکان را می‌دهد تا از طریق آزمون و خطا بهترین راهکارها را برای انجام یک عمل یاد بگیرد. در این روش، مدل به جای برچسب، از یک تابع پاداش استفاده می‌کند که مشخص می‌کند چه اقداماتی باعث نتیجهٔ بهینه می‌شود. از کاربردهای یادگیری تقویتی می‌توان به بازی‌ها [۱۹]، کنترل رباتیک [۲۰] و سیستم‌های توصیه‌گر [۲۱] اشاره کرد.

---

[۱۸] Spam Detection
[۱۹] Games
[۲۰] Robotic Control
[۲۱] Recommender Systems

### ۵.۲.۲ معرفی چند مدل از الگوریتم یادگیری کلاسیک

نزدیک‌ترین همسایه

الگوریتم نزدیک‌ترین همسایه [۲۲] یکی از روش‌های ساده و درعین‌حال کارآمد در یادگیری نظارت‌شده است که هم در دسته‌بندی و هم در رگرسیون کاربرد دارد [۷، ۱۲، ۳۵]. این الگوریتم برای پیش‌بینی دسته‌بندی یک نمونهٔ جدید، به $k$ نزدیک‌ترین داده‌ها در فضای ویژگی نگاه می‌کند و بر اساس اکثریت نزدیکی همسایه‌ها، آن را به یک دسته اختصاص می‌دهد.

مزایا:

- سادگی و قابل فهم بودن: این الگوریتم به سادگی با اندازه‌گیری فاصله بین نقاط داده کار می‌کند و بدون نیاز به آموزش مدل پیچیده قابل استفاده است [۷].
- عملکرد خوب در داده‌های با تعداد ویژگی کم: در مسائلی که تعداد ویژگی‌ها کم است، این الگوریتم اغلب به خوبی عمل می‌کند [۲۳].

معایب:

- حساسیت به داده‌های پرت: نقاط پرت می‌توانند به‌طور قابل توجهی بر نتایج تأثیر بگذارند [۱۲].
- کندی در داده‌های بزرگ: این الگوریتم نیاز به محاسبه فاصله برای هر نقطهٔ جدید دارد و در داده‌های بزرگ بار محاسباتی بالایی خواهد داشت [۳۵].
- عدم کارایی در داده‌های با ابعاد بالا: در داده‌هایی با تعداد ویژگی‌های زیاد، کارایی الگوریتم کاهش می‌یابد [۳۷].

[۲۲] k-Nearest Neighbors

### ۶.۲.۲ ماشین بردار پشتیبان

الگوریتم ماشین بردار پشتیبان [۲۳] با یافتن یک ابرصفحهٔ بهینه، داده‌ها را به کلاس‌های مختلف تقسیم می‌کند [۶، ۴۷]. این الگوریتم یک ابرصفحه به دست می‌آورد که هدف آن حداکثر کردن فاصله میان داده‌های دو کلاس است و به این ترتیب می‌تواند طبقه‌بندی دقیقی داشته باشد.

مزایا:

- توانایی مقابله با داده‌های پیچیده و ابعاد بالا: SVM می‌تواند به خوبی با داده‌های چندبعدی و پیچیده کار کند [۴۷].
- مقاومت در برابر بیش‌برازش [۲۴]: با استفاده از هسته‌ها ([۲۵])، داده‌های غیرخطی نیز به فضای بالاتر برده می‌شوند و جداسازی بهتری انجام می‌شود [۶].

معایب:

- پیچیدگی محاسباتی: آموزش ماشین بردار پشتیبان به دلیل نیاز به حل مسائل بهینه‌سازی، در حجم‌های بالای داده محاسباتی زمان‌بر است [۳۷].
- کارایی پایین در داده‌های پرت: در صورتی که داده‌ها شامل نقاط پرت زیادی باشند، دقت مدل کاهش می‌یابد [۴].

[۲۳] Support Vector Machine, SVM
[۲۴] Overfitting
[۲۵] kernels

### ۷.۲.۲ بیز ساده

بیز ساده [۲۶] مبتنی بر قضیه بیز [۲۷] است و فرض می‌کند ویژگی‌ها به‌صورت شرطی مستقل از هم هستند [۱۰، ۳۵]. این مدل برای اولین بار در حوزهٔ پردازش متن به کار رفت و هنوز هم در بسیاری از کاربردها مانند طبقه‌بندی ایمیل و تحلیل احساسات مورد استفاده قرار می‌گیرد [۳۱]. در بیز ساده بر اساس احتمالات محاسبه می‌شود که یک نمونهٔ جدید به کدام دسته تعلق دارد. این الگوریتم بر اساس قضیهٔ بیز، احتمال تعلق یک نمونه به هر دسته را به ازای هر ویژگی محاسبه کرده و در نهایت بالاترین احتمال را به‌عنوان جواب نهایی در نظر می‌گیرد [۴].

مزایا:

- سرعت بالا: به دلیل محاسبات ساده و فرض استقلال ویژگی‌ها، بیز ساده بسیار سریع و کم‌حجم است [۳۱].
- کارایی در داده‌های کوچک: حتی با داده‌های کم، این الگوریتم عملکرد نسبتاً خوبی دارد [۳۷].

معایب:

- فرض استقلال ویژگی‌ها: فرض استقلال ویژگی‌ها ممکن است در بسیاری از مسائل واقعی صادق نباشد و این می‌تواند دقت مدل را کاهش دهد [۱۰].
- حساسیت به داده‌های نادرست: در صورت وجود داده‌های نادرست یا پرت، مدل ممکن است دقت کمتری داشته باشد [۴].

[۲۶] Bayes Naive
[۲۷] Bayes' theorem

### ۸.۲.۲ شبکه‌های عصبی بازگشتی و شبکه‌های حافظه بلندمدت کوتاه‌مدت

شبکه‌های عصبی بازگشتی [۲۸] و مدل‌هایی با حافظهٔ بلندمدت_کوتاه‌مدت [۲۹] با هدف پردازش داده‌های ترتیبی و وابسته به زمان توسعه یافتند [۴۳، ۲۰]. این مدل‌ها به‌ویژه در تحلیل زبان طبیعی، پردازش صوت و پیش‌بینی سری‌های زمانی بسیار موفق عمل کرده‌اند؛ زیرا قادر به حفظ اطلاعات گذشته هستند و از این اطلاعات برای پیش‌بینی در لحظهٔ حال و آینده استفاده می‌کنند [۱۵].

### ۹.۲.۲ شبکه‌های عصبی بازگشتی

مدل‌های اولیهٔ شبکه‌های عصبی، مانند شبکه‌های چندلایه [۳۰]، قادر به پردازش داده‌های مستقل و ثابت بودند و نمی‌توانستند وابستگی‌های زمانی را یاد بگیرند. [۴]. در بسیاری از مباحث دنیای واقعی مانند تحلیل متن و صدا، داده‌ها به توالی خاصی وابسته هستند. به همین دلیل، شبکه‌های شبکه‌های عصبی بازگشتی معرفی شدند تا بتوانند از اطلاعات پیشین در پردازش داده‌های بعدی استفاده کنند [۴۳].

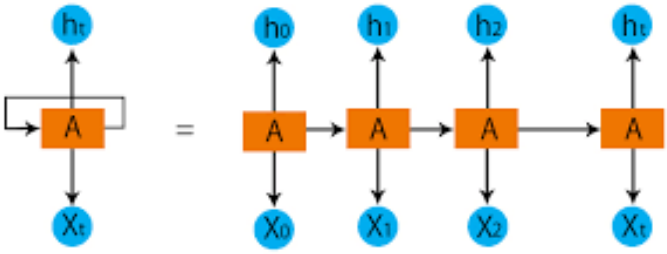


شکل ۲.۲.۱: RNN

---

[۲۸] RNN
[۲۹] LSTM
[۳۰] MLP

ساختار و عملکرد شبکه‌های عصبی بازگشتی

شبکه‌های شبکه‌های عصبی بازگشتی دارای حلقهٔ بازگشتی هستند که به مدل این امکان را می‌دهد اطلاعات را در توالی نگه دارد و در هر گام زمانی، ورودی فعلی $x_t$ و وضعیت قبلی $h_{t-1}$ را به‌عنوان ورودی دریافت کند [۱۶]:

$$h_t = \sigma\big(W \cdot x_t + U \cdot h_{t-1} + b\big) \tag{۲.۲.۱}$$

در اینجا:

- $h_t$ وضعیت مخفی یا حالت در گام زمانی $t$ است.
- $W$ وزن‌هایی است که به ورودی $x_t$ اعمال می‌شود.
- $U$ وزن‌های اعمال‌شده به وضعیت قبلی $h_{t-1}$ است.
- $b$ بایاس مدل است.
- $\sigma$ تابع فعال‌سازی، معمولاً تانژانت هیپربولیک یا سیگموید.

با استفاده از این فرایند، مدل این توانایی را دارد که اطلاعات گذشته را در خود ذخیره کرده و در پردازش‌های بعدی از آن‌ها بهره ببرد.

### ۱۰.۲.۲ مزایا و معایب شبکه‌های عصبی بازگشتی

در این قسمت به مزایا و معایب شبکه‌های شبکه‌های عصبی بازگشتی می‌پردازیم.

مزایا:

- حفظ وابستگی زمانی: شبکه‌های عصبی بازگشتی قادر به پردازش توالی‌های طولانی است و می‌تواند اطلاعات را در طول توالی به خاطر بسپارد [۱۳].

- کاربردهای گسترده در داده‌های ترتیبی: این مدل در تحلیل زبان طبیعی، پیش‌بینی سری‌های زمانی و پردازش صوت بسیار موفق عمل می‌کند [۱۵].

معایب:

- مشکل ناپدید شدن و انفجار گرادیان [۳۱]: در فرایند آموزش با روش پس‌انتشار، اگر توالی داده‌ها طولانی باشد، گرادیان‌ها ممکن است بسیار کوچک یا بزرگ شوند که منجر به ناپایداری در آموزش و کاهش دقت می‌شود [۱۹].

- محدودیت در پردازش توالی‌های بسیار بلند: شبکه‌های عصبی بازگشتی در حفظ اطلاعات طولانی‌مدت با مشکل مواجه است و برای پردازش وابستگی‌های طولانی، عملکرد ضعیفی دارد [۲۰، ۱۶].

### ۱۱.۲.۲ شبکه‌های حافظه بلندمدت_ کوتاه‌مدت

علل پیدایش شبکه‌های حافظه بلندمدت_ کوتاه‌مدت

شبکه‌های حافظه بلندمدت_ کوتاه‌مدت به عنوان یک راه‌حل برای یکی از بزرگ‌ترین مشکلات شبکه‌های عصبی بازگشتی معرفی شدند [۲۰]. یکی از برجسته‌ترین مشکلات موجود در شبکه‌های عصبی بازگشتی، معضل ناپدید شدن گرادیان بود که مانع یادگیری وابستگی‌های بلندمدت می‌شد [۱۹، ۱۶]. برای درک عمیق‌تر این مسأله، ابتدا به توضیح مشکل ناپدید شدن گرادیان و سپس راهکار شبکه‌های حافظه بلندمدت_ کوتاه‌مدت می‌پردازیم.

ناپدید شدن گرادیان

شبکه‌های عصبی بازگشتی برای پردازش داده‌های ترتیبی از حلقه‌های بازگشتی بهره می‌برند. در فرایند آموزش شبکه‌های عصبی بازگشتی، از الگوریتم پس‌انتشار خطا از طریق زمان [۳۲] استفاده می‌شود که

[۳۱] Vanishing and Exploding Gradient
[۳۲] Backpropagation Through Time

گرادیان‌ها را جهت به‌روزرسانی وزن‌ها محاسبه می‌کند.

[۴۳]. با این حال، شبکه های عصبی بازگشتی در یادگیری وابستگی‌های بلندمدت معمولاً ناکام می‌مانند. علت اصلی این امر شامل موارد زیر است:

- ضریب‌های بازگشتی کوچک‌تر از ۱: در فرایند محاسبهٔ گرادیان‌ها، اگر مقدار مشتقات یا ضرایب در هر مرحله کوچک‌تر از ۱ باشد، ضرب مکرر این ضرایب در طول توالی منجر به کوچک‌شدن گرادیان‌ها به سمت صفر می‌شود؛ پدیده‌ای که به ناپدید شدن گرادیان معروف است [۱۹].

فرمول کلی گرادیان در زمان $t$ به‌صورت زیر است:

$$\frac{\partial L}{\partial W} = \prod_{k=1}^{t} \frac{\partial h_k}{\partial h_{k-1}} \cdot \frac{\partial h_t}{\partial L} \tag{۲.۲.۲}$$

در این فرمول، $\frac{\partial h_k}{\partial h_{k-1}}$ ممکن است مقداری کوچک‌تر از ۱ باشد، و ضرب مکرر آن در طول توالی باعث کاهش شدید مقدار گرادیان می‌گردد.

- تأثیر مستقیم بر وزن‌ها: زمانی که گرادیان‌ها به صفر نزدیک می‌شوند، وزن‌های مدل عملاً به‌روزرسانی نمی‌شوند و این امر مانع از یادگیری وابستگی‌های طولانی‌مدت در داده‌ها می‌شود [۱۶].

### ۱۲.۲.۲ ظهور شبکه‌های حافظهٔ بلندمدت_ کوتاه‌مدت

در سال ۱۹۹۷ ،شبکه‌های حافظهٔ بلندمدت_ کوتاه‌مدت معرفی شد. [۲۰]. انگیزهٔ اصلی توسعهٔ این شبکه حل مشکل ناپدید شدن گرادیان در شبکه‌های عصبی بازگشتی بود. این مشکل در مسائل یادگیری داده‌های ترتیبی طولانی مانع می‌شد شبکه های عصبی بازگشتی وابستگی‌های بلندمدت را به‌درستی فراگیرد.

راه‌حل شبکه‌های حافظه بلندمدت_ کوتاه‌مدت برای پایداری جریان گرادیان‌ها

با معرفی معماری جدید در شبکه‌های بازگشتی، جریان گرادیان‌ها را در طول توالی پایدار نگه می‌دارد. این کار از طریق اضافه کردن وضعیت سلولی [۳۳] و دروازه‌ها [۳۴] به ساختار شبکه‌های عصبی بازگشتی انجام می‌شود. [۱۵]. این اجزا به این شبکه این امکان را می‌دهند:

۱. اطلاعات غیرضروری را فراموش کند،

۲. اطلاعات مهم جدید را اضافه کند،

۳. اطلاعات مهم قبلی را حفظ کند.

## ۳.۲ ساختار شبکه های حافظه بلند_ مدت کوتاه_ مدت

شبکه های حافظه بلند_ مدت شامل اجزای جدیدی است که به آن امکان مدیریت بهتر اطلاعات را می‌دهد:

### ۱.۳.۲ وضعیت سلولی

مسیر اصلی ذخیرهٔ اطلاعات در شبکه های حافظه بلند_ مدت کوتاه مدت است که می‌تواند اطلاعات مهم را در طول توالی حفظ کند. برخلاف شبکه های عصبی بازگشتی که عمدتاً بر خروجی‌های بازگشتی $h_t$ متکی است، LSTM یک مسیر جداگانه برای عبور اطلاعات از وضعیت سلولی دارد که به حفظ گرادیان‌ها کمک شایانی می‌کند [۲۰].

[۳۳] Cell State
[۳۴] Gates

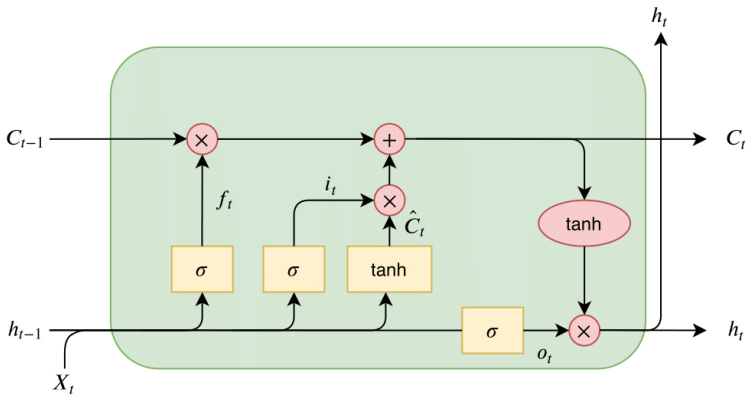


شکل ۲.۳.۲: LSTM

### ۲.۳.۲ دروازه‌ها

دروازه‌ها نقش فیلترهای اطلاعاتی را دارند که جریان اطلاعات را در طول فرایند یادگیری کنترل می‌کنند:

- دروازهٔ فراموشی [۳۵] تعیین می‌کند چه اطلاعاتی از وضعیت سلولی باید حذف شود [۱۵]:

$$f_t = \sigma\big(W_f \cdot [h_{t-1}, x_t] + b_f\big) \tag{۲.۳.۳}$$

$f_t$ : میزان فراموشی برای هر عنصر از وضعیت سلولی ,

$\sigma$ : تابع سیگموید (خروجی بین ۰ و ۱) .

در صورت $f_t = 0$، اطلاعات حذف می‌شود و در صورت $f_t = 1$، حفظ می‌شود.

- دروازهٔ ورودی [۳۶]: تعیین می‌کند چه اطلاعات جدیدی باید به وضعیت سلولی اضافه شود:

$$i_t = \sigma\big(W_i \cdot [h_{t-1}, x_t] + b_i\big) \tag{۲.۳.۴}$$

[۳۵] Forget Gate
[۳۶] Input Gate

$$\tilde{C}_t = \tanh\left(W_C \cdot [h_{t-1}, x_t] + b_C\right) \qquad (۲.۳.۵)$$

که در آن $i_t$ میزان اطلاعات جدید و $\tilde{C}_t$ مقدار جدید قابل اضافه‌شدن به وضعیت سلولی را نشان می‌دهد.

- دروازهٔ خروجی [۳۷]:

تعیین می‌کند چه اطلاعاتی از وضعیت سلولی به خروجی منتقل شود:

$$o_t = \sigma\left(W_o \cdot [h_{t-1}, x_t] + b_o\right),$$

$$h_t = o_t \cdot \tanh(C_t).$$

### ۳.۳.۲ به‌روزرسانی وضعیت سلولی

وضعیت سلولی $C_t$ با استفاده از اطلاعات جدید و قدیمی به‌روزرسانی می‌شود:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \qquad (۲.۳.۶)$$

این ساختار باعث می‌شود اطلاعات قدیمی مهم حفظ و داده‌های غیرضروری حذف شوند.

علت پایداری گرادیان در شبکه های حافظه بلندـ مدت کوتاه مدت

- حذف ضرب‌های مکرر: برخلاف شبکه های بازگشتی که به ضرب‌های مکرر وزن‌ها و گرادیان‌ها وابسته است، شبکه های حافظه بلندـ مدت کوتاه مدت با مسیر جداگانهٔ وضعیت سلولی، از کاهش نمایی گرادیان جلوگیری می‌کند [۱۹].

[۳۷] Output Gate

- استفاده از توابع سیگموید و تانژانت هیپربولیک: توابع سیگموید در دروازه‌ها و تانژانت هیپربولیک در وضعیت سلولی مقادیر را محدود می‌کنند و مانع از انفجار گرادیان می‌شوند [۱۵، ۱۶].

- مدیریت اطلاعات توسط دروازه‌ها: دروازه‌های فراموشی و ورودی به مدل اجازه می‌دهند تنها اطلاعات مهم حفظ شود و داده‌های غیرضروری حذف شوند؛ این موضوع از پیچیدگی محاسباتی غیرضروری جلوگیری می‌کند [۲۰].

| ویژگی | RNN | LSTM |
|---|---|---|
| مشکل ناپدید شدن گرادیان | وجود دارد | برطرف شده |
| توانایی حفظ وابستگی‌های طولانی‌مدت | محدود به وابستگی کوتاه‌مدت | بسیار خوب |
| ساختار دروازه‌ها | ندارد | دارای دروازه‌های فراموشی، ورودی و خروجی |
| پایداری گرادیان | ضعیف | پایدار |

جدول ۲.۳.۱: مقایسه ویژگی‌های RNN و LSTM

### ۴.۳.۲ مشکلات کلی شبکه های بازگشتی و ظهور مبدل ها

شبکه‌های بازگشتی که به آن ها پرداخته شد توانستند بسیاری از مشکلات و محدودیت‌های مدل‌های اولیه را حل کنند؛ اما همچنان با چالش‌ها و محدودیت‌هایی مواجه بودند که در مسائل پیچیده‌تر، مانند ترجمهٔ زبان یا تحلیل داده‌های بلندمدت و حجیم، مشکلات جدی ایجاد می‌کردند [۲۰، ۱۶]. این مشکلات در نهایت به پیدایش مبدل‌ها [۳۸] منجر شد. [۴۸]. در ادامه، مهم‌ترین محدودیت‌های RNN و LSTM مورد بررسی قرار می‌گیرند.

مشکل وابستگی ترتیبی در شبکه های بازگشتی

شبکه های بازگشتی داده‌ها را به‌صورت ترتیبی پردازش می‌کنند؛ به این معنی که برای پردازش داده‌های گام زمانی $t$، باید تمامی داده‌های قبلی $(t-1)$ پردازش شده باشند [۴۳، ۲۰]. این ویژگی مشکلات

[۳۸] Transformers

زیر را ایجاد می‌کند:

- غیرقابل موازی‌سازی: به دلیل وابستگی ترتیبی، پردازش داده‌ها به‌صورت موازی ممکن نیست و همین امر باعث افزایش زمان محاسباتی می‌شود. در داده‌های بلند (مانند متن‌های طولانی یا سری‌های زمانی بزرگ)، این مشکل نمود بیشتری دارد.
- کندی آموزش و استنتاج: پردازش خطی داده‌ها موجب می‌شود زمان آموزش و پیش‌بینی مدل‌ها به‌شدت افزایش یابد، به‌ویژه زمانی که با حجم زیادی از داده مواجه هستیم.

محدودیت در یادگیری وابستگی‌های بسیار طولانی

با وجود پیشرفت شبکه های حافظه بلندـ مدت کوتاه مدت در یادگیری وابستگی‌های بلندمدت نسبت به شبکه های بازگشتی معمولی، این مدل‌ها همچنان در یادگیری وابستگی‌های بسیار بلند، مانند ارتباط بین کلمات در جملات دور از هم یا درک ساختار کلی یک متن، محدودیت دارند [۱۹]:

- مشکل در داده‌های بسیار طولانی: حتی در شبکه های حافظه بلندـ مدت کوتاه مدت نیز ظرفیت حفظ اطلاعات محدود است و با افزایش طول توالی، دقت مدل افت می‌کند.
- تأثیر تدریجی داده‌های اولیه: داده‌های ابتدایی توالی ممکن است با گذشت زمان اهمیت خود را از دست بدهند، چراکه گرادیان‌ها به‌تدریج ضعیف‌تر می‌شوند.

پیچیدگی محاسباتی و حافظه

شبکه های حافظه بلندـ مدت کوتاه مدت به علت ساختار پیچیده‌ای که شامل چندین ماتریس ضرب (برای دروازه‌های فراموشی، ورودی و خروجی) و به‌روزرسانی وضعیت سلول است، به حافظه و محاسبات زیادی نیاز دارند [۱۶]:

- نیاز به حافظه بیشتر: برای ذخیرهٔ وضعیت سلولی و گرادیان‌ها، شبکه های حافظه بلندـ مدت کوتاه مدت به حافظهٔ بیشتری نسبت به مدل‌های ساده‌تر احتیاج دارند.

- هزینهٔ محاسباتی بالا: در داده‌های حجیم، انجام محاسبات سنگین می‌تواند اجرای مدل را بسیار کند سازد.

مشکل پردازش وابستگی‌های غیرمتوالی

شبکه های بازگشتی به‌طور طبیعی برای یادگیری وابستگی‌های محلی و متوالی مناسب هستند. اما در مسائلی مانند ترجمهٔ زبان یا تحلیل متون، روابط غیرمحلی و غیرمتوالی نیز اهمیت دارند [۲]. به‌عنوان مثال، در جمله‌ای طولانی ممکن است کلمه‌ای در ابتدای جمله با کلمه‌ای در انتهای جمله ارتباط معنایی داشته باشد. شبکه های بازگشتی برای یادگیری این‌گونه وابستگی‌ها محدودیت دارند.

گرادیان‌های ناپایدار و مشکلات بهینه‌سازی

با وجود بهبودهایی که شبکه حافظه بلند_مدت کوتاه_مدت نسبت به شبکه های بازگشتی معمولی در پایداری گرادیان ارائه داد، هنوز هم:

- مسائل گرادیان‌های ناپایدار: در توالی‌های بسیار بلند، گرادیان‌ها ممکن است همچنان دچار کاهش یا حتی در مواردی انفجار شوند.
- مشکلات بهینه‌سازی: در مسائلی با ساختار پیچیده، یافتن مینیمم مناسب تابع هزینه برای شبکه های بازگشتی دشوار است.

نیاز به مدلی با ظرفیت بیشتر و سرعت بالاتر

- مدل‌های بزرگ‌تر: برای مسائل پیچیده‌تر، به مدل‌هایی با تعداد پارامتر بالاتر نیاز است؛ اما این شبکه های بازگشتی به‌دلیل محدودیت در حافظه و پردازش، پاسخ‌گوی این نیاز نیستند.
- کارایی در داده‌های چندوجهی [۳۹]:

[۳۹] Multimodal

برای داده‌هایی که ترکیبی از اطلاعات متنی، صوتی و تصویری هستند،شبکه های بازگشتی توانایی لازم جهت پردازش موازی این اطلاعات را ندارند.

در مجموع، وابستگی ترتیبی در شبکه های بازگشتی مانعی اساسی برای استفاده از این مدل‌ها در مسائل پیچیده و بزرگ بود که درنهایت به ظهور مبدل ها منتهی شد [۴۸]. مبدل‌ها با طراحی مبتنی بر موازی‌سازی و مکانیزم توجه [۴۰]، این محدودیت را برطرف کرده و راه‌حلی کارآمدتر برای پردازش داده‌های ترتیبی ارائه دادند.

[۴۰] Attention Mechanism

# فصل ۳

# پیشینه پژوهش

## ۱.۳ مقدمه

ظهور مبدل‌ها یکی از تحولات اساسی در حوزهٔ پردازش زبان طبیعی [۱] و یادگیری ماشین به شمار می‌رود.

[۴۸، ۲]. این مدل‌ها باعث تغییرات عمده‌ای در نحوهٔ ساخت و آموزش مدل‌های زبانی و همچنین در بسیاری از کاربردهای دیگر یادگیری ماشین شده‌اند و توانستند بسیاری از مشکلات مدل‌های قبلی را حل کنند[۹، ۴۲].

## ۲.۳ مشکلات ترجمه ماشینی و مبدل ها

در ابتدا، ترجمه ماشینی [۲] یک چالش اساسی در زمینهٔ پردازش زبان طبیعی بود. مدل‌های اولیه‌ای مانند مدل‌های مبتنی بر قواعد [۳] برای ترجمه استفاده می‌شدند که در آن‌ها، ترجمه‌ها به‌صورت دستی

[۱] NLP
[۲] machine translation
[۳] Rule-based Models

با استفاده از قواعد زبانی مشخص تنظیم می‌شدند [۳۸، ۲۱]. این روش‌ها هرچند دقیق بودند، اما محدودیت‌های زیادی داشتند و نمی‌توانستند ویژگی‌های پیچیده‌تر زبان را مدل‌سازی کنند.

سپس مدل‌های آماری [۴] معرفی شدند [۵، ۲۴]. این مدل‌ها از داده‌های ترجمه‌شده برای آموزش مدل‌های آماری استفاده می‌کردند که احتمال ترجمهٔ صحیح را براساس شواهد آماری محاسبه می‌کردند. مدل‌هایی مانند مدل‌های ترجمهٔ آماری مبتنی بر جمله [۵] [۲۵] از این نوع بودند که قادر به ترجمهٔ جملات بهتر از مدل‌های مبتنی بر قواعد بودند، اما هنوز هم در ترجمه‌های پیچیده با مشکلاتی روبه‌رو بودند.

بعد از این مدل‌ها، مدل‌های بازگشتی [۶] به وجود آمدند که مشکلات آن‌ها در فصل گذشته بیان شد [۱۳، ۴۵]. در نهایت، این مشکلات باعث به وجود آمدن ترانسفورمرها شد [۲].

## ۳.۳ ظهور ترانسفورمرها

در سال ۲۰۱۷، مقاله‌ای توسط گوگل [۷] منتشر شد که مفهوم جدیدی به نام مبدل ها [۸] را معرفی کرد [۴۸]. این مقاله به موضوع ترجمهٔ ماشینی پرداخت و نشان داد که با استفاده از مکانیزم توجه می‌توان بسیاری از مشکلات مدل‌های قبلی را حل کرد [۳۰].

مدل‌های ترانسفورمر برخلاف مدل‌های قبلی که از پردازش سریالی استفاده می‌کردند، از پردازش موازی بهره می‌برند. این ویژگی به ترانسفورمرها اجازه می‌دهد که به‌طور همزمان به تمام بخش‌های ورودی توجه کنند. این قابلیت باعث شد که ترانسفورمرها در پردازش تصویر و متن بسیار سریع‌تر و دقیق‌تر از مدل‌های قبلی عمل کنند [۴۸].

[۴] Statistical Models
[۵] Phrase-based Statistical Models
[۶] Recurrent Models
[۷] google
[۸] Transformers

## ۴.۳ معماری ترانسفورمرها

در تصویر ۳.۴.۱، معماری ترانسفورمر نمایش داده شده است و بخش‌ها و اجزای مختلف آن مشخص شده است. معماری ترانسفورمر از دو بخش اصلی تشکیل شده است:

- رمزگذار [۹]:

وظیفهٔ انکودر این است که دادهٔ ورودی را دریافت کند و ویژگی‌های آن را استخراج کند.

- رمزگشا [۱۰]:

وظیفهٔ دیکودر این است که ویژگی‌های استخراج‌شده را به زبان مقصد تبدیل کند.

### ۱.۴.۳ جاسازی

ددر زبان طبیعی، کلمات به شکل رشته‌های متنی هستند مانند کتاب، ماشین و ... کامپیوترها نمی‌توانند به‌طور مستقیم این کلمات را به شکل رشته‌های متنی پردازش کنند. به همین دلیل، در یادگیری ماشین این کلمات را به شکل یک بردار نمایش می‌دهیم. این بردار بیانگر آن کلمه در مدل است تا ماشین بتواند آن کلمه را پردازش کند [؟].

این بردارها ویژگی‌های کلمه را در فضای عددی نمایش می‌دهند. روش‌های مختلفی برای تبدیل متن به بردار وجود دارند. از جمله این روش‌ها می‌توان به روش‌های Word2Vec [۳۴] و GloVe [۴۱] اشاره کرد.

همان‌طور که در شکل ۳.۴.۲ نشان داده شده است، هر کلمه که به صورت توکن است، ابتدا در دیکشنری تعریف‌شده پیدا می‌شود و پس از پیدا شدن در دیکشنری، با استفاده از روش‌های [۱۱]، هر کلمه به برداری از اعداد تبدیل می‌شود. این جاسازی‌ها شباهت‌های معنایی بین کلمات را مدل‌سازی

[۹] Encoder
[۱۰] Decoder
[۱۱] Embedding

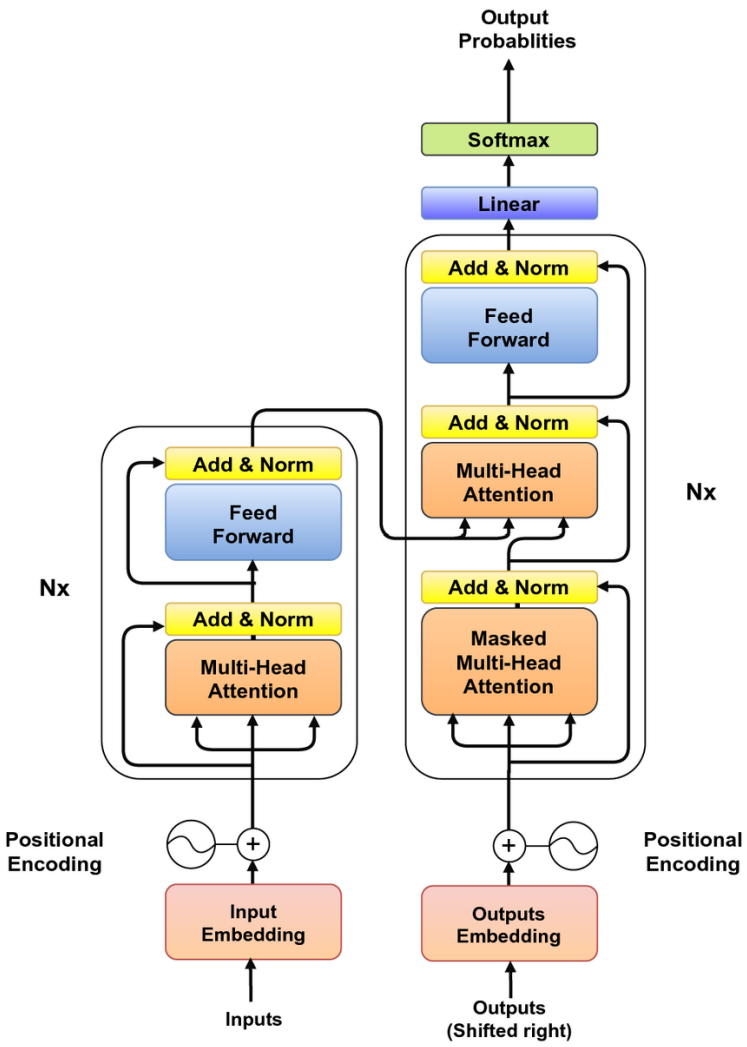


شکل ۳.۴.۱: معماری ترانسفورمرها

می‌کنند و کلماتی که از نظر معنایی شبیه به هم هستند، بردار آن‌ها نیز به یکدیگر نزدیک‌تر است. به این ترتیب، کلمات برای مدل‌ها و شبکه‌های عصبی قابل‌فهم می‌شوند [۳۴، ۴۱].

### ۲.۴.۳ جاسازی موقعیتی

تا الان هر کلمه را به برداری از اعداد که برای مدل قابل فهم باشد، تبدیل کرده‌ایم. اما مدل‌های ترانسفورمر نمی‌توانند جایگاه هر کلمه را تشخیص دهند. در مدل‌های ترانسفورمر، برخلاف مدل‌های بازگشتی، به دلیل اینکه کلمات به‌صورت موازی وارد می‌شوند، نیاز داریم تا جایگاه هر کلمه را بدانیم.

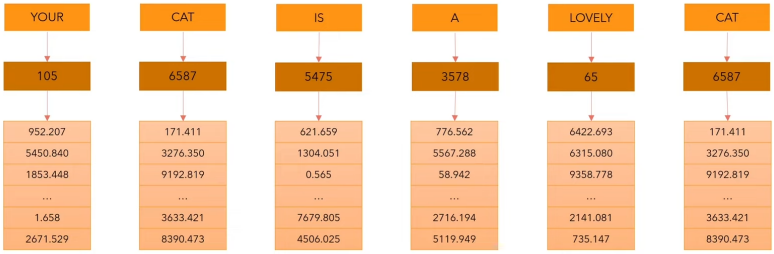


شکل ۳.۴.۲: word embedding

به‌طور مثال، در جملهٔ «من تو را دوست دارم» باید به‌طور دقیق بدانیم که «من» کلمهٔ اول جمله است، «تو» کلمهٔ دوم جمله است و ... .

حال باید به مدل توالی این کلمات را بفهمانیم. بنابراین، نیاز داریم به مدل یک سری اطلاعات اضافی بدهیم به‌طوری‌که مدل توالی کلمات را یاد بگیرد. روش‌های مختلفی برای اضافه‌کردن جاسازی موقعیتی [۱۲] به مدل وجود دارد. در ترانسفورمرها از روش جاسازی موقعیت سینوسی [۱۳] استفاده می‌شود [۴۸].

این روش قابل یادگیری نیست و صرفاً از یک سری فرمول‌های ساده برای جاسازی موقعیتی استفاده می‌کند. برای موقعیت [۱۴] در توالی و بُعد $i$ در فضای برداری، تعبیهٔ موقعیتی به‌صورت زیر تعریف می‌شود:

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{\frac{2i}{d}}}\right) \tag{۳.۴.۱}$$

و برای مقادیر فرد:

$$PE(pos, 2i+1) = \cos\left(\frac{pos}{10000^{\frac{2i}{d}}}\right) \tag{۳.۴.۲}$$

[۱۲] Positional Embedding
[۱۳] Sinusoidal Positional Embedding
[۱۴] pos

- $pos$: موقعیت کلمه در توالی است (مثلاً از $0$ تا $N-1$ برای یک توالی $N$ـ تایی).
- $i$: شاخص بعد در بردار موقعیتی (از $0$ تا $d-1$ برای بعد فضای برداری $d$).
- $d$: ابعاد فضای برداری مدل که نشان می‌دهد هر کلمه در چند بعد نمایش داده می‌شود.
- $10000$: یک مقدار ثابت برای تنظیم مقیاس توابع تناوبی و ایجاد فرکانس‌های مختلف در ابعاد گوناگون.

همان‌طور که در شکل شکل ۳.۴.۳ مشاهده می‌کنید، بعد از جاسازی کلمات، به آن جا سازی موقعیتی اضافه می‌شود. در این روش از توابع سینوس و کسینوس استفاده می‌شود. این توابع موقعیت‌ها را در فضای برداری به‌گونه‌ای نگاشت می‌کنند که مدل بتواند از ترتیب کلمات در توالی آگاه باشد [۴۸]. این ویژگی به مدل کمک می‌کند تا توالی زمانی را درک کرده و الگوهای زمانی را شبیه‌سازی کند. از مزایای این روش می‌توان به عدم نیاز به آموزش و توزیع متوازن جایگاه کلمات اشاره کرد.

شکل ۳.۴.۳: word embedding + positional embedding

### ۳.۴.۳ توجه

در روش شبکه های بازگشتی، توالی ورودی (مثلاً یک جمله) معمولاً به‌صورت گام‌به‌گام پردازش می‌شد [۱۳، ۲۰]. اما در ترانسفورمر می‌خواهیم مدلی داشته باشیم که به هر موقعیت (مثلاً یک

کلمه) در توالی نگاه کند و به همهٔ موقعیت‌های دیگر نیز به‌صورت موازی دسترسی داشته باشد. به این مفهوم توجه می‌گوییم.

به زبان ساده، وقتی توکن (کلمه) $i$ به توکن‌های دیگر نگاه می‌کند، می‌خواهد بداند کدام توکن‌ها برای تفسیر معنای خودش مهم‌ترند.

به طور مثال در جمله‌ی «یک گربه روی زمین نشسته است» می‌خواهد بداند کلمه‌ی «گربه» به واژه‌ی «نشستن» بیشتر توجه کند یا به «زمین». در این‌جا فعل «نشستن» ارتباط نزدیک‌تری به «گربه» دارد و از نظر معنایی مرتبط‌تر است.

$$Q = \text{(پرسش) Query}, \quad K = \text{(کلید) Key}, \quad V = \text{(مقدار / ارزش) Value}$$

در ضرب شباهت های توجه [۱۵] [۴۸]، ابتدا شباهت یا ارتباط بین پرسش [۱۶] و کلید [۱۷] را با محاسبهٔ ضرب داخلی [۱۸] به‌دست می‌آوریم، سپس آن را نرمال می‌کنیم (با تقسیم بر $d_k$) و از تابع سافت مکس [۱۹] استفاده می‌کنیم تا ضرایب توجه [۲۰] را به‌دست آوریم. در نهایت با همین ضرایب، ترکیبی خطی از بردارهای مقدار [۲۱] را می‌گیریم.

فرمول به‌شکل زیر است:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{۳.۴.۳}$$

که در آن:

[۱۵] Scaled Dot-Product Attention
[۱۶] Query
[۱۷] Key
[۱۸] Dot Product
[۱۹] softmax
[۲۰] Attention Weights
[۲۱] value

ماتریس پرسش برای $Q \in \mathbb{R}^{n \times d_k}$

ماتریس کلید برای $K \in \mathbb{R}^{n \times d_k}$

ماتریس مقدار $V \in \mathbb{R}^{n \times d_v}$

تقسیم بر $d_k$ باعث می‌شود مقدار ضرب داخلی در ابعاد بالا خیلی بزرگ نشود و شیب‌ها گرادیان پایدار بمانند.

$$\alpha = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \tag{۳.۴.۴}$$

$\alpha$ یک ماتریس با ابعاد $n \times n$ است که سطر $i$ـ‌ام آن ضرایب توجه برای توکن $i$ را نشان می‌دهد.

تفسیر ضرایب توجه: هر سطر از $\alpha$ نشان می‌دهد که توکن فعلی به چه توکن‌هایی در جمله، با چه شدتی توجه می‌کند.

ایدهٔ چندسری [۲۲] به‌جای آنکه فقط یک‌بار $Q, K, V$ بسازیم و عملیات توجه را انجام دهیم، چندین مجموعهٔ متفاوت $Q_i, K_i, V_i$ می‌سازیم (هر کدام یک «سر» [۲۳] یا سر نام دارد) و به‌صورت موازی محاسبات توجه را انجام می‌دهیم. سپس خروجی همهٔ این سرها را کنار هم قرار داده [۲۴] و در نهایت با یک ماتریس وزن دیگر ضرب می‌کنیم تا به بعد اصلی بازگردیم.

فرمول مربوط به این ایده به‌شکل زیر است:

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i) \tag{۳.۴.۵}$$

$$\text{MultiHead}(Q, K, V) = [\text{head}_1 \oplus \cdots \oplus \text{head}_h]W_O \tag{۳.۴.۶}$$

[۲۲] multi head attention
[۲۳] head
[۲۴] concatenate

| | YOUR | CAT | IS | A | LOVELY | CAT |
|---|---|---|---|---|---|---|
| YOUR | 0.268 | 0.119 | 0.134 | 0.148 | 0.179 | 0.152 |
| CAT | 0.124 | 0.278 | 0.201 | 0.128 | 0.154 | 0.115 |
| IS | 0.147 | 0.132 | 0.262 | 0.097 | 0.218 | 0.145 |
| A | 0.210 | 0.128 | 0.206 | 0.212 | 0.119 | 0.125 |
| LOVELY | 0.146 | 0.158 | 0.152 | 0.143 | 0.227 | 0.174 |
| CAT | 0.195 | 0.114 | 0.203 | 0.103 | 0.157 | 0.229 |

شکل ۳.۴.۴: توجه

که در آن $\oplus$ نشان‌دهندهٔ عمل الحاق [۲۵] است.

ماتریس وزن $W_O$ به‌شکل زیر است:

$$W_O \in \mathbb{R}^{(h \cdot d_v) \times d_{\text{model}}}$$

که $W_O$ ماتریسی است که خروجی الحاق‌شده را به بعد $d_{\text{model}}$ برمی‌گرداند.

## چرا چندین سر؟

مشاهدهٔ چند منظر متفاوت: هر سر می‌تواند الگوهای گوناگونی از وابستگی‌ها را بیاموزد (مثلاً یک سر می‌تواند یاد بگیرد کلمهٔ فعلی با کلمات همسایهٔ نزدیک خود بیشتر مرتبط شود، یک سر دیگر

[۲۵] concatenate

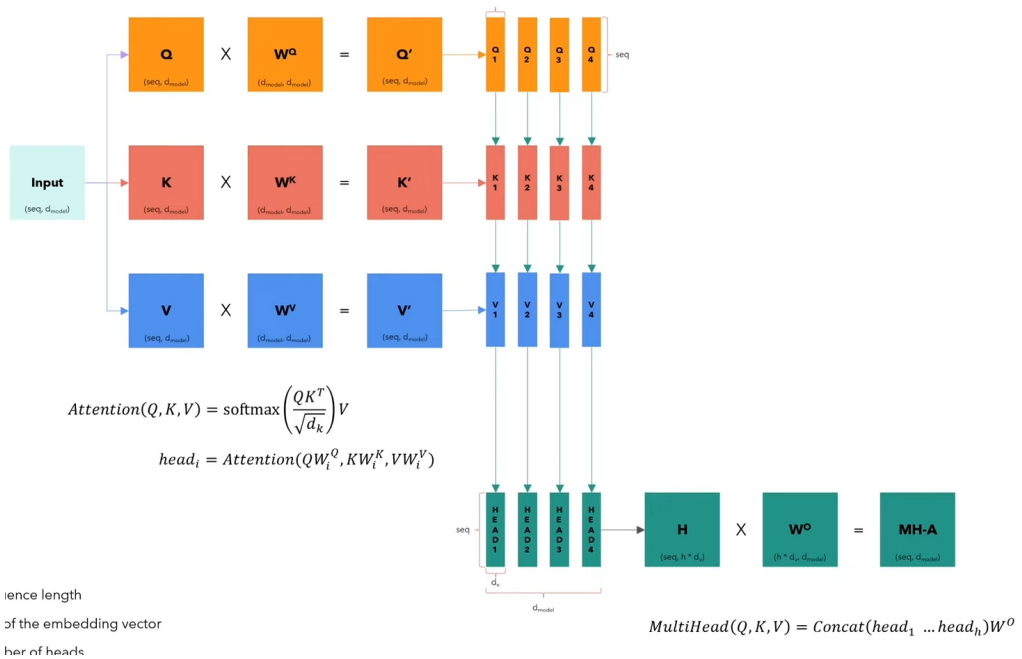


شکل ۳.۴.۵: multi head attention

روی ارتباط با کلماتی در فاصلهٔ دورتری متمرکز باشد، سر دیگر روی مطابقت جنس و تعداد در دستور زبان و ...).

افزایش ظرفیت مدل: با داشتن چند سر ، مدل می‌تواند قدرت بیان بیشتری داشته باشد.

ابعاد کمتر در هر سر: در عمل، اگر $d_{\text{model}}$ مثلاً ۵۱۲ باشد، و تعداد سر ها $h = 8$، آنگاه هر سر ابعادی در حدود $d_k = 64$ خواهد داشت؛ و این محاسبات ضرب داخلی را نیز مقیاس پذیر و قابل موازی‌سازی می‌کند.

### ۴.۴.۳ اتصال باقی مانده

در معماری‌های عمیق، هنگامی که تعداد لایه‌ها زیاد می‌شود، اغلب دچار ناپایداری گرادیان می‌شوند و این مشکل باعث دشواری در آموزش مدل می‌گردد [۲۰، ۳].

در مبدل ها [۴۸]، به جای این که خروجی توجه را به‌صورت مستقیم به لایهٔ بعدی بدهیم، ورودی آن را نیز حفظ کرده و به خروجی اضافه می‌کنیم. ایدهٔ اصلی این روش از اتصالات باقی‌مانده [۲۶] در

[۲۶] Residual Connection

شبکه‌های عمیق الهام گرفته شده است [۱۷].

اگر $x$ ورودی به زیرماژول و $\text{SubLayer}(x)$ خروجی آن زیرماژول باشد، در انتهای کار عبارت زیر را محاسبه می‌کنیم:

$$x + \text{SubLayer}(x) \tag{۳.۴.۷}$$

این جمع به‌صورت عنصر به‌عنصر Element-wise Addition انجام می‌شود.

### ۵.۴.۳ مزایای اتصال باقی مانده در ترانسفورمر

#### کمک به جریان یافتن گرادیان

وقتی ورودی مستقیماً به خروجی اضافه می‌شود، مسیری مستقیم برای عبور شیب (گرادیان) به عقب ایجاد می‌گردد. در صورت نبود این اتصال، اگر شبکه عمیق شود، گرادیان‌ها ممکن است در لایه‌های پایین محو شوند و عملاً gradient vanishing رخ دهد [۲۰، ۳].

#### حفظ اطلاعات اصلی (هویت ورودی)

حتی اگر زیرماژول تغییری در اطلاعات ورودی ایجاد کند، با وجود Residual Connection، ورودی اصلی همواره در خروجی نهایی حضور دارد. این ویژگی باعث می‌شود در صورت ناکافی‌بودن یادگیری زیرماژول یا در مراحل اولیهٔ آموزش، دست‌کم بخشی از سیگنال (اطلاعات) خام به لایه‌های بالاتر برسد [۱۷، ۴۸].

#### کاهش ریسک تخریب ویژگی‌ها

در شبکه‌های عمیق، یکی از مشکلات این است که هر لایه ممکن است بخشی از اطلاعات مفید را تخریب کند. اتصال باقی مانده تضمین می‌کند که اگر لایه‌ای به هر دلیل نتوانست الگوی بهینه را یاد بگیرد، اطلاعات قبلی حداقل به‌صورت دست‌نخورده تا حدی منتقل می‌شود.

## ۵.۳ نرمال سازی لایه ها

در یادگیری عمیق، نرمال‌سازی [۲۷] داده‌های یک لایه یا فعال‌سازی‌ها، اغلب به سرعت بخشیدن به همگرایی و پایدار کردن آموزش کمک شایانی می‌کند. شاید معروف‌ترین نوع نرمال‌سازی، نرمال سازی بچ [۲۸] باشد که پیش‌تر در کارهای بینایی کانولوشنی[۲۹] بسیار مورداستفاده قرار گرفت [۲۲].

نرمال سازی لایه ها [۳۰] روشی جایگزین است که در ترانسفورمر استفاده می‌شود [۱، ۴۸]. علت اصلی این انتخاب، ماهیت توالی‌محور [۳۱] بودن داده‌ها در پردازش زبان طبیعی و عدم تمایل به وابستگی به آمار مینی‌بچ است.

### تفاوت نرمال سازی بچ ها با نرمال سازی لایه ها

#### Batch Normalization

در نرمال سازی بچ ها، برای نرمال‌سازی، میانگین و واریانس روی تمام نمونه‌های موجود در مینی‌بچ [۳۲] (و نیز در طول ابعاد ویژگی) محاسبه می‌شود [۲۲]. این موضوع در پردازش زبان طبیعی کمی دردسرساز است؛ چون ترتیب توکن‌ها، طول جمله‌ها و حتی اندازهٔ مینی‌بچ ممکن است نامنظم باشد. همچنین به خاطر تنوع طول توالی‌ها، پیاده‌سازی نرمال سازی بچ ها می‌تواند پیچیده شود.

#### Layer Normalization:

در نرمال سازی لایه ها، برای هر توکن به‌صورت جداگانه (در طول بُعد ویژگی)، میانگین [۳۳] و واریانس [۳۴] گرفته می‌شود [۱]. فرض کنید در یک لایه، بردار $h_i \in \mathbb{R}^{d_{\text{model}}}$ مربوط به توکن $i$ باشد؛

[۲۷] Normalization
[۲۸] Batch Normalization
[۲۹] CNN
[۳۰] Layer Normalization
[۳۱] sequence
[۳۲] mini-batch
[۳۳] mean
[۳۴] variance

یعنی ابعاد ویژگی آن $d_{\text{model}}$ است. ما میانگین $\mu_i$ و واریانس $\sigma_i^2$ را از اجزای این بردار محاسبه می‌کنیم:

$$\mu_i = \frac{1}{d_{\text{model}}} \sum_{k=1}^{d_{\text{model}}} h_{i,k}, \quad \sigma_i^2 = \frac{1}{d_{\text{model}}} \sum_{k=1}^{d_{\text{model}}} (h_{i,k} - \mu_i)^2 \tag{۳.۵.۸}$$

سپس نرمال‌سازی برای هر مؤلفهٔ $k$ در بردار توکن $i$ به شکل زیر انجام می‌شود:

$$\hat{h}_{i,k} = \frac{h_{i,k} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}} \tag{۳.۵.۹}$$

در نهایت، برای این‌که مدل بتواند مقیاس و بایاس جدیدی یاد بگیرد، شبیه بچ نرم ، دو پارامتر $\gamma$ و $\beta$ نیز در طول بعد ویژگی اعمال می‌شوند:

$$\text{LayerNorm}(h_i) = \gamma \odot \hat{h}_i + \beta \tag{۳.۵.۱۰}$$

که در آن $\gamma, \beta \in \mathbb{R}^{d_{\text{model}}}$ هستند و $\odot$ ضربِ عنصر به عنصر است [۱].

## مزایای نرمال سازی لایه در مبدل ها

- بی‌نیازی از وابستگی به ابعاد مینی‌بچ: با نرمال سازی لایه، می‌توان حتی با اندازهٔ مینی‌بچ برابر ۱ نیز به‌خوبی آموزش دید، چراکه آمارها وابسته به ابعاد ویژگی‌اند و نه مینی‌بچ [۱].
- پایدارسازی توزیع فعال‌سازی‌ها: زمانی که مدل در حال یادگیری است، توزیع‌های داخلی لایه‌های میانی ممکن است تغییر کند.[۳۵] نرمال سازی لایه با نرمال‌سازی این توزیع، آموزش را پایدارتر و سریع‌تر می‌کند [۲۲، ۱].

[۳۵] Internal Covariate Shift

- سازگاری با داده‌های توالی‌محور: هر توکن را جداگانه نرمال می‌کند و نگرانی‌ای بابت ترتیب طول جمله‌ها، یا قرار گرفتن چند جملهٔ کوتاه/بلند در یک مینی‌بچ نداریم [۴۸].

در معماری مبدل ها، پس از خروجی هر زیرماژول، مراحل به‌شکل زیر است:

اتصال باقی مانده ابتدا ورودی همان زیرماژول (مثلاً بردار $x$) را با خروجی زیرماژول ($\text{SubLayer}(x)$) جمع می‌کنیم. حاصل این جمع را می‌توان چنین نوشت:

$$z = x + \text{SubLayer}(x) \tag{۳.۵.۱۱}$$

این $z$ حالا ترکیبی از اطلاعات اصلی ورودی و اطلاعات یادگرفته‌شده توسط SubLayer است.

نرمال سازی لایه سپس این بردار $z$ را وارد لایهٔ LayerNorm می‌کنیم:

$$y = \text{LayerNorm}(z)$$

خروجی نهایی را می‌توان به لایهٔ بعدی پاس داد یا به مرحلهٔ بعدی در همین لایه.
به‌عبارتی اگر بخواهیم در یک فرمول واحد بیان کنیم:

$$\text{Norm \& Add} = \text{LayerNorm}\big(x + \text{SubLayer}(x)\big)$$

## ۶.۳ رمزگشا

دیکودر در معماری ترانسفورمرها وظیفهٔ تولید خروجی نهایی را بر عهده دارد. این خروجی معمولاً می‌تواند توالی هدف [۳۶] باشد، مانند ترجمهٔ یک جمله یا پیش‌بینی توکن‌های بعدی در یک توالی [۴۸].

[۳۶] Target Sequence

در این بخش، دیکودر دو ورودی اصلی دارد: ۱. توالی هدف که معمولاً به‌صورت خودکار تولید می‌شود (مثلاً در ترجمهٔ ماشینی یا تولید متن)، ۲. نمایش اطلاعات کدشده که توسط انکودر تولید شده است و شامل ویژگی‌های استخراج‌شده از توالی ورودی می‌باشد.

دیکودر از این ورودی‌ها استفاده می‌کند تا به‌صورت گام‌به‌گام، خروجی نهایی خود را تولید کند [۲، ۴۵].

همان‌طور که در شکل ۳.۶.۶ مشاهده می‌کنید، دیکودر دو ورودی دارد.

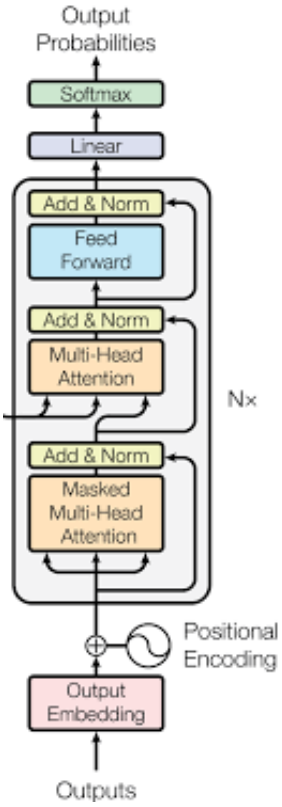


شکل ۳.۶.۶: Decoder

تمامی بخش‌های دیکودر مانند انکودر هستند اما در دیکودر توجه چند سر ماسک شده [۳۷] وجود دارد [۴۸].

[۳۷] Masked Multi-Head Attention

## ۷.۳ توجه چند سری ماسک شده

در مبدل‌ها، مکانیزم توجه چند سری [۳۸] در بخش دیکودر به‌صورت ماسک شده [۳۹] پیاده‌سازی می‌شود تا مدل نتواند توکن‌های آینده را ببیند و به‌صورت خودبازگشتی [۴۰] توکن بعدی را پیش‌بینی کند [۴۸].

در واقع ایدهٔ اصلی استفاده از ماسک جلوگیری از مشاهدهٔ آینده است.

در معماری‌های خودبازگشتی، مدل در گام $i$ از دیکودر تنها باید به توکن‌های قبلی $\{y_1, \ldots, y_{i-1}\}$ دسترسی داشته باشد؛ اما نه به توکن‌های $\{y_{i+1}, y_{i+2}, \ldots\}$. اگر مدل بتواند توکن‌های آینده را «نگاه» کند، پیش‌بینی توکن بعدی آسان و غیرواقعی می‌شود (مشکل نشت اطلاعات) [۲، ۴۵].

به همین دلیل در توجه چند سری ماسک شده در دیکودر، از یک ماتریس ماسک $M$ استفاده می‌کنیم که اجازه نمی‌دهد هر توکن به توکن‌های آینده‌اش توجه کند.

## ۸.۳ مثال عددی توجه ماسک شده

فرض کنید دنبالهٔ ۴ توکنی داریم:

$$[y_1, y_2, y_3, y_4]$$

خروجی ضرب داخلی (قبل از `softmax`) یک ماتریس $4 \times 4$ خواهد بود:

$$S = \begin{bmatrix} s_{1,1} & s_{1,2} & s_{1,3} & s_{1,4} \\ s_{2,1} & s_{2,2} & s_{2,3} & s_{2,4} \\ s_{3,1} & s_{3,2} & s_{3,3} & s_{3,4} \\ s_{4,1} & s_{4,2} & s_{4,3} & s_{4,4} \end{bmatrix}$$

- سطر ۱ (توکن اول): تنها می‌تواند خودش (ستون ۱) را ببیند، اما ستون‌های ۲ تا ۴ ماسک می‌شوند.

---

[۳۸] Multi-Head Attention
[۳۹] Masked
[۴۰] Autoregressive

- سطر ۲ (توکن دوم): می‌تواند به ستون‌های ۱ و ۲ نگاه کند، اما ستون‌های ۳ و ۴ ماسک می‌شوند.
- سطر ۳: می‌تواند ستون‌های ۱، ۲ و ۳ را ببیند، اما ستون ۴ ماسک می‌شود.
- سطر ۴: می‌تواند به ستون‌های ۱، ۲، ۳ و ۴ دسترسی داشته باشد (چهارمین توکن می‌تواند توکن‌های قبلی را ببیند. همچنین این توکن خودش نیز معمولاً در دسترس است — بسته به پیاده‌سازی، ممکن است توکن فعلی از خودش نیز استفاده کند یا نه. در معماری استاندارد، سطر $i$ معمولاً به ستون $i$ هم دسترسی دارد).

در عمل، ماتریس ماسک $M$ به شکل زیر خواهد بود (با نشانه‌گذاری پایین‌مثلثی):

$$M = \begin{bmatrix} 0 & -\infty & -\infty & -\infty \\ 0 & 0 & -\infty & -\infty \\ 0 & 0 & 0 & -\infty \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

به این ترتیب، پس از جمع شدن با $S$ و اجرای `softmax` در هر سطر، ضرایب توجه ستون‌های ماسک‌شده به صفر میل می‌کنند [۴۸].

## ۹.۳ مبدل های بینایی

ایدهٔ ترانسفورمرها در حوزهٔ بینایی [۴۱] از تعمیم ترانسفورمر متن به تصاویر به وجود آمده است [۱۱].

ما در این بخش از مبدل های بینایی برای وظیفه کلاس‌بندی استفاده می‌کنیم.

در روش‌های متداول برای پردازش تصویر، از کانولشن [۴۲] های متوالی استفاده می‌کردند؛ اما در ترانسفورمرها تصاویر به پچ‌های مختلف شکسته می‌شوند [۱۱]. هر پچِ شکسته‌شده از تصویر

[۴۱] vision transformer
[۴۲] convolution

می‌تواند با سایر پچ‌ها به‌صورت موازی وارد مکانیزم توجه شود و شباهت یا ارتباطشان با یکدیگر سنجیده شود. در بخش‌های بعد، به‌طور مفصل روند انجام این کار را توضیح خواهیم داد.

### ۱.۹.۳

در ترانسفورمرهای مبتنی بر متن، هر کلمه به توکن تبدیل می‌شود و سپس هر کلمه به برداری تبدیل می‌گردد. این بردارها پس از افزودن جاسازی موقعیتی وارد مکانیزم توجه می‌شوند [۴۸].

حال همین ایده در تصویر پیاده‌سازی شده است. همان‌طور که در شکل ۳.۹.۷ مشاهده می‌کنید، در مبدل های بینایی، به‌جای استفاده از عملیات کانولوشن‌های متوالی که در شبکه‌های CNN مرسوم است [۲۷، ۲۶، ۱۷]، تصویر را به بلاک‌های غیرهم‌پوشان $(P \times P)$ تقسیم می‌کنیم. این کار علاوه بر ساده‌سازی موازی‌سازی، به مدل اجازه می‌دهد از سازوکار Self-Attention برای ارتباط بین این بلاک‌ها استفاده کند [۱۱].

شکل ۳.۹.۷: patch to image

### ۲.۹.۳ شکل پچ‌ها:

فرض کنید ابعاد تصویر ورودی $(H \times W \times C)$ باشد. به‌عنوان مثال، اگر اندازهٔ تصویر $224 \times 224 \times 3$ باشد، طول و عرض تصویر به‌ترتیب 224 و تصویر دارای سه کانال رنگی است:

$$H = 224, \quad W = 224, \quad C = 3$$

شکل ۳.۹.۸: Image original

حال اگر اندازهٔ هر پچ ($P \times P$) باشد (برای نمونه $16 \times 16$)، تصویر به‌صورت یک جدول مشبک از پچ‌های کوچک تقسیم می‌شود. به هر پچ می‌توان مانند یک «کاشی» از تصویر نگاه کرد: - پچ اول: مختصات ( در ارتفاع15 تا 0) و ( در عرض15 تا 0)، - پچ دوم: مختصات ( در ارتفاع15 تا 0) و ( در عرض31 تا 16)، - و به همین ترتیب تا کل تصویر پوشش داده شود.

### ۳.۹.۳ تعداد پچ‌ها:

اگر پچ‌ها بدون هم‌پوشانی باشند، ابعاد پچ باید بر ابعاد تصویر بخش‌پذیر باشد.

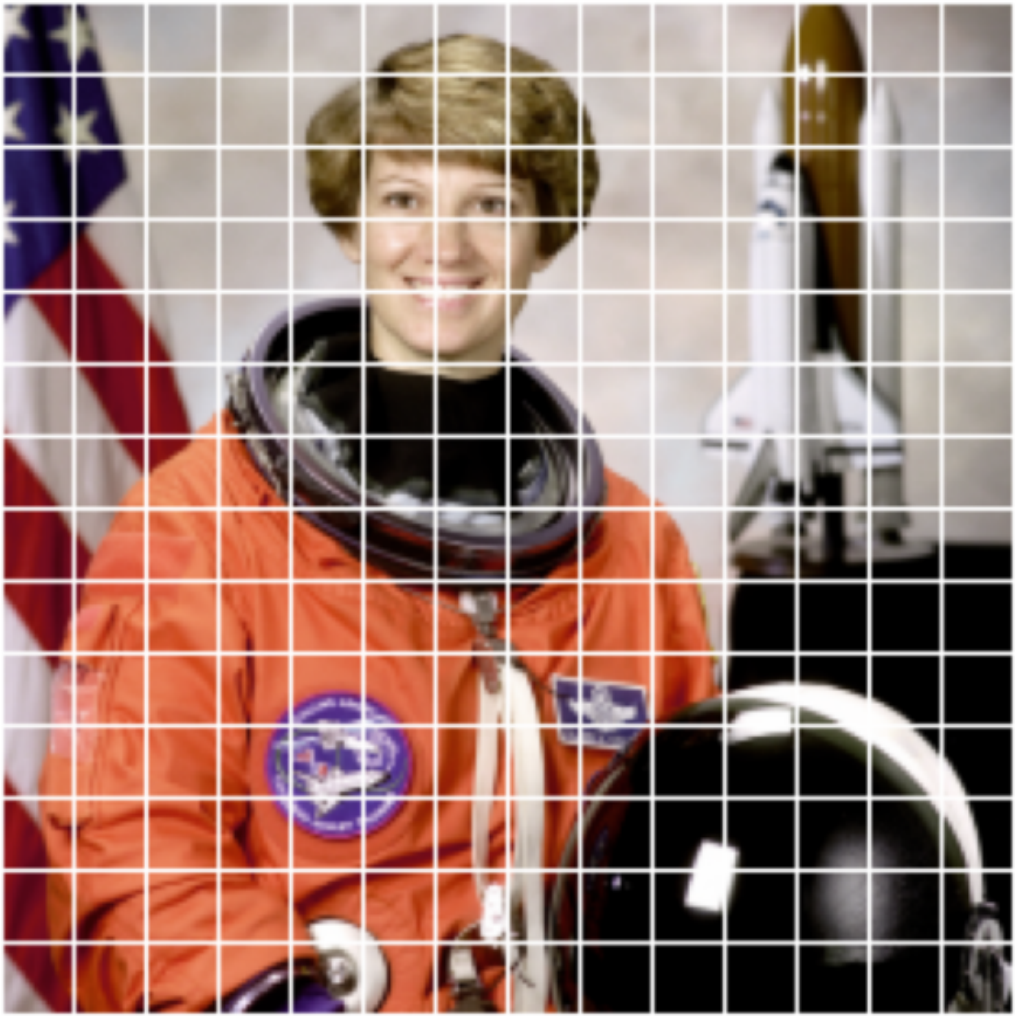

شکل ۳.۹.۹: paches of image

- تعداد پچ‌های افقی: $\frac{W}{P}$ - تعداد پچ‌های عمودی: $\frac{H}{P}$

در مجموع:

$$\left(\frac{H}{P}\right) \times \left(\frac{W}{P}\right) = \frac{H}{P} \times \frac{W}{P}. \tag{۳.۹.۱۲}$$

برای مثال اگر:

$$H = 224, \quad W = 224, \quad P = 16 :$$

$$\frac{224}{16} = 14 \quad \Rightarrow \quad 14 \times 14 = 196 \quad \text{(تعداد پچ‌ها)}.$$

در اکثر نسخه‌های مبدل‌های بینایی، پچ‌ها بدون هم‌پوشانی [۴۳] هستند. اندازهٔ پچ‌های کوچک باعث می‌شود تعداد پچ‌ها زیاد شود و در نتیجه هزینهٔ توجه بالا رود. از طرفی، پچ‌های بزرگ هزینهٔ توجه را کاهش می‌دهند؛ اما ممکن است جزییات محلی [۴۴] را از دست بدهیم [۱۱].

### ۴.۹.۳ بردارکردن هر پچ

هر پچ دارای ابعاد $(P \times P \times C)$ است. برای مثال اگر $P = 16$ و $C = 3$، آنگاه پچ ابعاد $16 \times 16 \times 3$ خواهد داشت. برای این‌که بتوانیم پچ‌ها را مانند «توکن»های پردازش زبان طبیعی به مبدل ها بدهیم، باید آن‌ها را به یک بردار یک بعدی تبدیل کنیم. در صورت قرار دادن پیکسل‌های پچ به‌صورت ردیفی [۴۵]، طول این بردار خواهد بود:

$$P \times P \times C = P^2 \times C. \tag{۳.۹.۱۳}$$

در مثال $(16 \times 16 \times 3)$، طول بردار می‌شود 768.

## ۱۰.۳ اعمال لایهٔ خطی

بعد از کنار هم چیدن پچ ها [۴۶] کردن، معمولاً یک لایهٔ خطی [۴۷] روی این بردار اعمال می‌شود تا آن را به بعد $d_{\text{model}}$ (مثلاً ۷۶۸ یا ۱۰۲۴) ببرد. در حقیقت، این لایه یک تبدیل ویژگی [۴۸] انجام می‌دهد تا همهٔ پچ‌ها یک نمایندگی (Embedding) با ابعاد یکنواخت $d_{\text{model}}$ پیدا کنند:

$$(P^2 \times C) \quad \rightarrow \quad d_{\text{model}}$$

---

[۴۳] Non-overlapping
[۴۴] Local Details
[۴۵] Row-major
[۴۶] Flatten
[۴۷] Fully-Connected Layer
[۴۸] Feature Transformation

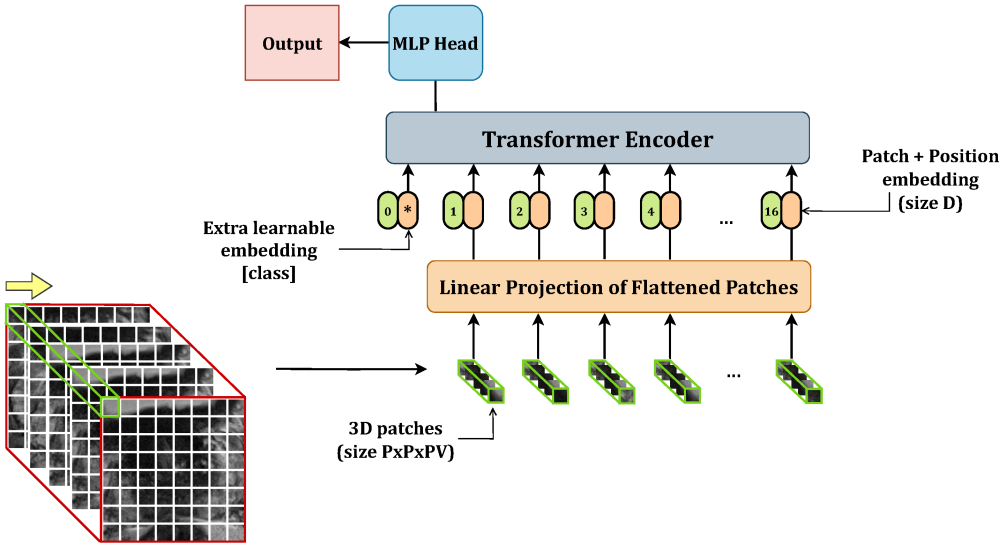


شکل ۳.۱۰.۱۰: مبدل های بینایی

این مرحله شبیه ساخت توکن در پردازش زبان طبیعی است؛ با این تفاوت که در پردازش زبان طبیعی، توکن «کلمه» یا «زیرکلمه» است و از قبل دارای بردار تعبیه‌شده جاساز شده بوده است [۴۸]. در مبدل های بینایی [۱۱]، ما ابتدا باید تصاویر را پچ کنیم و سپس بردارهای جاساز را از این پچ‌ها به دست آوریم.

ترانسفورمر نیاز دارد ورودی‌اش توالی توکن‌ها باشد. در پردازش زبان طبیعی توالی کلمات داریم، در مبدل های بینایی توالی «پچ»ها:

$$\{x_{\text{patch}_1}, x_{\text{patch}_2}, \ldots, x_{\text{patch}_N}\}.$$

هر پچ اکنون یک بردار $d_{\text{model}}$ـ بعدی است. پس یک مجموعه با طول $N$ (تعداد پچ‌ها) و عرض $d_{\text{model}}$ خواهیم داشت. اگر عدد پچ‌ها $N$ باشد (مثلاً ۱۹۶)، ترانسفورمر می‌تواند با مکانیزم توجه خود سر، وابستگی میان پچ‌ها را یاد بگیرد: کدام بخش از تصویر برای کدام بخش دیگر مهم‌تر است، چگونه ترکیب جهانی [۴۹] شکل گیرد. [۴۸، ۱۱].

معمولاً پچ‌ها را به‌صورت ردیفی شماره‌گذاری می‌کنند (ابتدا پچ‌های ردیف بالایی از چپ به

[۴۹] Global Context

راست، سپس ردیف بعدی و ...)، تا مدل در صورت نیاز بتواند از موقعیت‌ها، اطلاعات مکانی تقریبی داشته باشد. در عمل، چون قصد داریم (در مراحل بعد) به هر پچ یک جاسازی موقعیتی هم اضافه کنیم، مکان دقیق هر پچ در بُعد دوم (ویژگی) کد می‌شود.

در مبدل بینایی [۱۱] دیگر به کانولوشن وابسته نیستیم. در عوض، از جاساازی استفاده می‌شود. تقسیم کردن تصویر به بلاک‌های $(P \times P)$، کنار هم چیدن و تبدیل آن به جاساز همگی عملیات ریاضی ساده‌ای هستند که به‌راحتی روی TPU/GPU قابل موازی‌سازی‌اند.

### ۱.۱۰.۳ توکن کلاس بندی

توکن کلاس بندی [۵۰] یک بردار ویژه است که به ابتدای دنبالهٔ ورودی اضافه می‌شود و نقش آن، خلاصه‌کردن اطلاعات کل ورودی (چه متن، چه تصویر) است [۹، ۱۱].

در مبدل بینایی، این توکن در ابتدای پچ‌های تصویری قرار می‌گیرد. این توکن یک بردار با ابعاد $d_{\text{model}}$ است (همان ابعاد سایر توکن‌ها) و پارامتری یادگرفتنی محسوب می‌شود؛ یعنی مدل طی آموزش، مقادیر آن را برای ذخیره و تجمیع اطلاعات بهینه می‌کند.

در وظایف دسته‌بندی کلاس بندی، هدف این است که یک پیش‌بینی کلی برای کل ورودی (مثلاً یک جمله یا یک تصویر) ارائه دهیم؛ توکن کلاس بندی دقیقاً همین وظیفه را بر عهده دارد [۹]. این توکن از طریق مکانیزم توجه چند سر در مبدل ها با تمامی توکن‌های دیگر (پچ‌های تصویر) ارتباط می‌گیرد و اطلاعات مهم آن‌ها را در لایه‌های مختلف مبدل ها را به‌صورت تجمعی یاد می‌گیرد. به عبارتی، توکن کلاس بندی نقش نمایندهٔ کل تصویر یا متن را بر عهده دارد.

توکن کلاس بندی از طریق ضرب داخلی در مکانیزم توجه، می‌تواند به تمام پچ‌ها نگاه کند و با ضرایب توجه $(\alpha)$ مشخص کند که از هر پچ چه مقدار اطلاعات بگیرد. بدین‌ترتیب، به‌طور ضمنی یاد می‌گیرد روی ویژگی‌هایی که برای دسته‌بندی مهم هستند (نظیر الگوها، اشکال و بخش‌های کلیدی تصویر) متمرکز شود.

[۵۰] Cls Token

در طول لایه‌های ترانسفورمر، توکن کلاس بندی نقش محوری در خلاصه‌سازی بازنمایی کل تصویر ایفا می‌کند. این توکن به‌صورت پارامتر قابل یادگیری تعریف شده و در طول فرآیند آموزش به‌روزرسانی می‌شود [۹، ۱۱].

### ۲.۱۰.۳ انکودر در مبدل های بینایی

انکودر در ترانسفورمرها همانند مبدل اصلی است [۴۸]، با این تفاوت که در مبدل های بینایی [۱۱] دیگر به دیکودر نمی‌رویم. پس از عبور از بلاک‌های ترانسفورمر، در ساده‌ترین حالت یک لایهٔ خطی (Fully Connected) یا یک لایهٔ MLP (Multi-Layer Perceptron) بر روی بردار نهایی اعمال می‌شود و این لایه‌ها به تعداد کلاس‌ها خروجی می‌دهند. سپس خروجی هر لایه با گذر از تابع سافت مکس به احتمال هر کلاس تبدیل می‌شود و در نهایت مدل کلاس با بیشترین احتمال را به‌عنوان خروجی پیش‌بینی می‌کند.

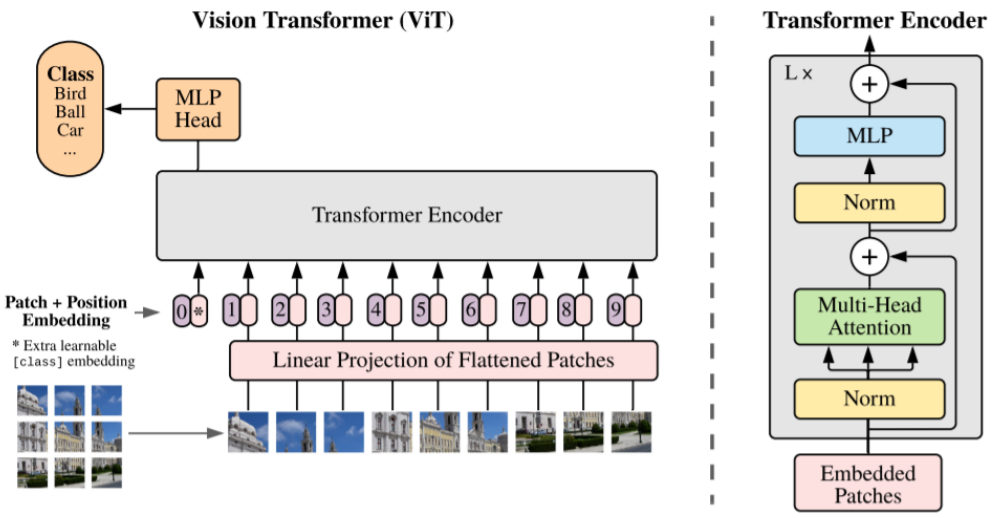


شکل ۳.۱۰.۱۱: توکن توجه در مبدل های بینایی

در مبدل ها، هر لایهٔ انکودر و دیکودر با پردازش عمیق‌تر روی توالی ورودی، می‌تواند نمایش بهتری از ویژگی‌ها به‌دست بیاورد [۴۸]. تکرار چندین‌بارهٔ انکودر یا دیکدر موجب می‌شود مدل بتواند ساختارهای پیچیده‌ای را یاد بگیرد و کیفیت و دقت آن در شناسایی توالی‌های طولانی و معانی

پنهان افزایش یابد [۴۸، ۱۱]. در نتیجه، مدل با تعداد لایه‌های بیشتر اغلب عملکرد بهتری از خود نشان می‌دهد.

## ۱۱.۳ مبدل پنجره‌ای متحرک

ایدهٔ مبدل پنجره‌ای متحرک [۵۱] از ترکیب چند مفهوم کلیدی در مدل‌های ترانسفورمر و شبکه‌های کانولوشنی شکل گرفت [۴۸، ۱۷، ۲۹].

یکی از بزرگترین مشکلات در ترانسفورمرهای اولیه، نیاز به محاسبات بسیار زیاد در زمانی بود که تصویر ورودی ابعاد بسیار بزرگی داشت [۱۱]. در ترانسفورمر معمولی هر پچ به تمامی پچ‌های دیگر توجه می‌کرد و در مواقعی که تعداد پچ‌ها زیاد می‌شد، هزینهٔ محاسباتی و حافظه به‌شدت افزایش پیدا می‌کرد.

در شبکه‌های کانولوشنی، معماری معمولاً به‌صورت سلسله‌مراتبی پیش می‌رود [۱۷]؛ یعنی ابتدا ویژگی‌های محلی استخراج می‌شود، سپس با عمیق‌تر شدن لایه‌ها، این ویژگی‌ها در سطوح بالاتر با یکدیگر ترکیب می‌شوند. در مبدل پنجره‌ای متحرک [۲۹]، با دانش بر این موضوع توانسته‌اند هم هزینه‌های محاسباتی را کاهش دهند و هم دقت مدل را افزایش دهند.

در مبدل پنجره‌ای متحرک، به‌جای آن‌که مدل به تمام پچ‌ها در یک سطح ویژگی نگاه کند، تصویر را به «پنجره‌های محلی» [۵۲] تقسیم می‌کند و توجه را محدود به همان ناحیه می‌سازد [۲۹]. سپس با تکنیک جابه‌جایی [۵۳] این پنجره‌ها در لایه‌های بعدی، توان مدل برای ترکیب اطلاعات از نواحی مختلف تصویر (و در نهایت دیدن کل تصویر) افزایش پیدا می‌کند. این رویکرد، ایدهٔ کلیدی‌ای بود که باعث شد مدل هم محاسبات سبک‌تری داشته باشد و هم بتواند ارتباط‌های جهانی [۵۴] را در طول لایه‌ها به‌دست آورد.

---

[۵۱] Swin Transformer
[۵۲] Local Windows
[۵۳] Shift
[۵۴] Global

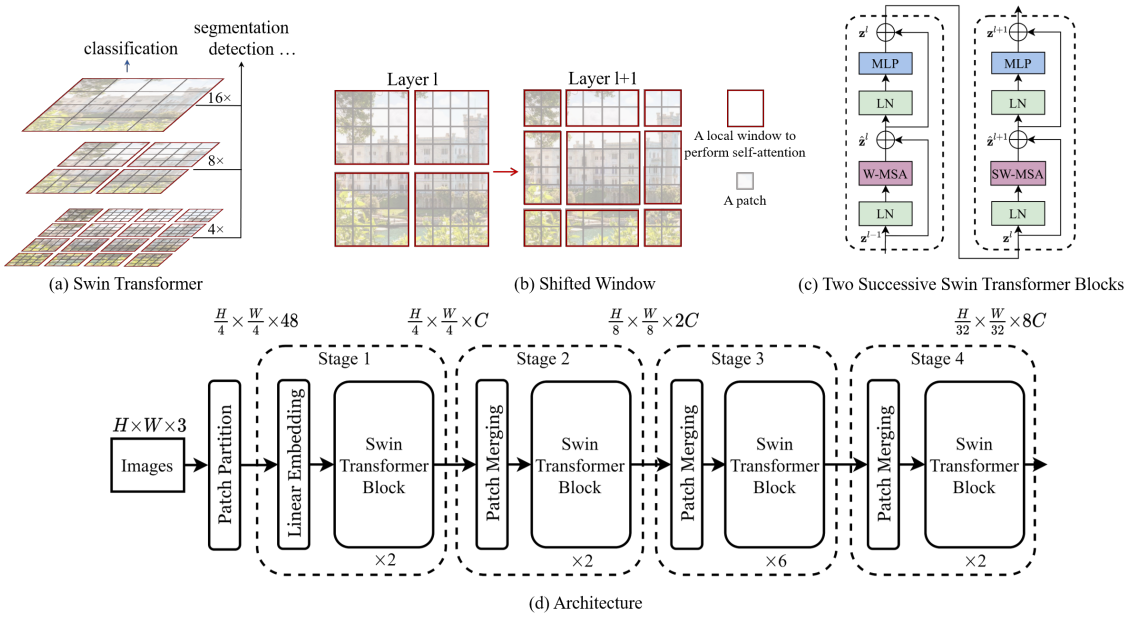


شکل ۳.۱۱.۱۲: مبدل پنجره متحرک

یکی دیگر از ایده‌های مهم در در مبدل پنجره‌ای متحرک، کوچک کردن تدریجی نقشهٔ ویژگی در طول معماری است؛ مشابه کاری که در ResNet یا سایر CNNها انجام می‌شود [۱۷]. این امر ضمن کاهش هزینهٔ محاسباتی، باعث می‌شود مدل بتواند با سطوح مختلفی از ویژگی‌ها کار کند و در نهایت خروجی نهایی باکیفیت‌تری ارائه دهد.

### ۳.۱۱.۱ قطعه‌بندی پچ

فرض کنیم تصویر ورودی $I$ دارای ابعاد $(H \times W \times 3)$ باشد. گام نخست، تقسیم تصویر به پچ‌های کوچک $(P \times P)$ است [۱۱]. اگر $P$ اندازهٔ پچ (Patch size) باشد، آنگاه تعداد پچ‌ها در بعد افقی و عمودی، به‌ترتیب $\frac{H}{P}$ و $\frac{W}{P}$ خواهد بود. هر پچ را می‌توان به‌صورت یک بردار درآورد:

$$X_{\text{patch}} \in \mathbb{R}^{(P^2 \cdot 3)}.$$

سپس کل تصویر به $\frac{H}{P} \times \frac{W}{P}$ پچ تبدیل خواهد شد و در نتیجه، ماتریس $X$ از کنار هم قرار

گرفتن این پچ‌ها به صورت زیر به‌دست می‌آید:

$$X \in \mathbb{R}^{\left(\frac{H}{P}\cdot\frac{W}{P}\right)\times\left(P^2\cdot 3\right)}.$$

### ۲.۱۱.۳ جاسازی

در ادامه، برای این‌که بتوانیم هر پچ را در یک فضای برداری با بعد $C$ (ابعاد مدل) نمایش دهیم، یک لایهٔ خطی (Fully Connected Layer) روی هر پچ اعمال می‌شود [۱۱، ۲۹]:

$$Z = X \cdot W_{\text{embed}} + b_{\text{embed}}, \quad Z \in \mathbb{R}^{\left(\frac{H}{P}\cdot\frac{W}{P}\right)\times C}. \tag{۳.۱۱.۱۴}$$

در عمل، این عملیات معادل یک تبدیل خطی ساده است:

$$W_{\text{embed}} \in \mathbb{R}^{\left(P^2\cdot 3\right)\times C}, \quad b_{\text{embed}} \in \mathbb{R}^{C}.$$

پس از این مرحله، ما در هر موقعیت $(h, w)$ (از شبکهٔ پچ‌ها) یک بردار $z_{h,w} \in \mathbb{R}^C$ داریم. این ماتریس $Z$ ورودیِ اولین مرحله (Stage) از مبدل های پنجره متحرک خواهد بود [۲۹].

هر بلوک مبدل پنجره متحرک از چند بخش اصلی تشکیل شده است [۲۹]:

- پنجره‌بندی تصویر [۵۵] یا پنجره‌بندی جابه‌جاشده [۵۶]
- اعمال توجه چمد سر پنجره ای [۵۷]
- لایهٔ Skip Connection [۵۸] و Layer Norm [۵۹]

[۵۵] Window Partition
[۵۶] Shifted Window Partition
[۵۷] Window Multi-Head Self Attention
[۵۸] Skip Connection
[۵۹] Layer Norm

- مسیر پرسیپترون چندلایه [۶۰]:

  - یک لایهٔ MLP شامل دو لایهٔ Fully-Connected [۶۱] و تابع فعال‌ساز GeLU [۶۲] (یا تابع مشابه)
  - لایهٔ Skip Connection [۶۳] و Layer Norm [۶۴]

### ۳.۱۱.۳ توجه چند سر پنجره ای

تعریف پنجره‌های محلی

در مبدل های پنجره متحرک، به‌جای آن‌که تمام پیکسل‌های یک نقشهٔ ویژگی بزرگ را یک‌جا در محاسبهٔ توجه درگیر کنیم، نقشهٔ ویژگی را به قطعه‌های کوچکی به‌اندازه $(M \times M)$ تقسیم می‌کنیم. این قطعه‌های کوچک را «پنجره‌های محلی» می‌نامیم.

اگر اندازهٔ نقشهٔ ویژگی در یک لایه $(H' \times W')$ باشد، با تقسیم آن به پنجره‌های $(M \times M)$، در راستای طول تقریباً $\frac{H'}{M}$ پنجره خواهیم داشت و در راستای عرض هم $\frac{W'}{M}$ پنجره. (برای راحتی، فرض می‌کنیم $H'$ و $W'$ دقیقاً مضربی از $M$ باشند تا تقسیم بدون باقی‌مانده انجام شود.)

هر کدام از این پنجره‌های $(M \times M)$ دارای $M^2$ پیکسل (یا موقعیت مکانی) است، و در هر پیکسل هم یک بردار ویژگی با بعد $C$ قرار دارد.

به بیان ساده‌تر:

- نقشهٔ ویژگی مثل یک صفحهٔ بزرگ است.
- آن را مانند شطرنج به مربع‌های کوچکی $(M \times M)$ بخش می‌کنیم.
- در هر مربع (پنجره)، فقط به همان مربع نگاه می‌کنیم و محاسبات توجه را انجام می‌دهیم.

---

[۶۰] MLP
[۶۱] Fully-Connected
[۶۲] GeLU
[۶۳] Skip Connection
[۶۴] Layer Norm

- این کار باعث می‌شود تعداد پیکسل‌هایی که درگیر محاسبهٔ توجه هستند، به‌مراتب کمتر شود و هزینهٔ محاسباتی کاهش یابد.

### ۴.۱۱.۳ توجه

برای هر بلوک، ابتدا بردارهای پرسش، کلید، مقدار ساخته می‌شوند. اگر $z_i \in \mathbb{R}^C$ بردار ورودی مربوط به موقعیت $i$ باشد، آنگاه:

$$q_i = z_i W_Q, \quad k_i = z_i W_K, \quad v_i = z_i W_V,$$

که

$$W_Q, W_K, W_V \in \mathbb{R}^{C \times d}.$$

پارامتر $d$ معمولاً به‌صورت $\frac{C}{h}$ در نظر گرفته می‌شود که در آن $h$ تعداد سربندی سر ها است. در توجه چند سر، خروجی نهایی با ترکیب $h$ سر توجه محاسبه می‌شود.

در یک سر توجه، توجه به‌صورت زیر تعریف می‌شود:

$$\text{Attention}(Q, K, V) = \text{Softmax}\Big(\frac{QK^\top}{\sqrt{d}}\Big) V,$$

که در آن:

- $Q, K, V$ به‌ترتیب ماتریس‌هایی هستند که از کنار هم قرار دادن $q_i, k_i, v_i$ (برای تمام پیکسل‌های آن پنجره) ساخته می‌شوند.

- $\sqrt{d}$: عامل مقیاس‌کننده برای جلوگیری از بزرگ شدن بیش‌ازحد ضرب داخلی است.

در مبدل های پنجره متحرک، این محاسبات به‌صورت پنجره‌ای انجام می‌شوند؛ یعنی برای هر پنجره، تنها پیکسل‌های داخل همان پنجره در ماتریس‌های $Q$، $K$ و $V$ لحاظ می‌شوند. به این ترتیب،

زمان محاسبه و مصرف حافظه به‌شدت کاهش می‌یابد (در مقایسه با مبدل های بینایی که همه‌چیز را با هم مقایسه می‌کند).

تعداد سربندی $h$ معمولاً طوری انتخاب می‌شود که $C = h \times d$. خروجی هر سر پس از محاسبهٔ Attention به‌صورت زیر با هم ادغام می‌شوند:

$$\mathrm{MultiHead}(Q, K, V) = \left[\mathrm{head}_1,\ \mathrm{head}_2,\ \ldots,\ \mathrm{head}_h\right] W_O,$$

که

$$\mathrm{head}_j = \mathrm{Attention}\big(Q_j,\ K_j,\ V_j\big), \quad W_O \in \mathbb{R}^{C \times C}$$

ماتریس ترکیب نهایی است.

### ۵.۱۱.۳ پنجره متحرک

در مدبل های پنجر متحرک، ایدهٔ «پنجره‌های جابه‌جاشده» [۶۵] به این منظور ارائه شده است تا مدل، ارتباط پیکسل‌های واقع در پنجره‌های مجاور را هم یاد بگیرد [۲۹]. اگر فقط از پنجره‌های ثابت (بدون جابه‌جایی) استفاده کنیم، هر بلوک از تصویر تنها با پیکسل‌های همان پنجره در ارتباط خواهد بود و ممکن است اطلاعات نواحی مرزی با نواحی مجاور به‌خوبی تبادل نشود.

روش مبدل های پنجره متحرک برای رفع این محدودیت از یک تکنیک ساده اما مؤثر استفاده می‌کند [۲۹]:

- در یک لایه، محاسبات توجه در پنجره‌های محلی ثابت انجام می‌شود.
- در لایهٔ بعدی، پنجره‌ها به اندازه‌ای مشخص جابه‌جا می‌شوند (به‌صورت شیفت افقی و عمودی) تا نواحی مرزی نیز در محاسبات گنجانده شوند.

[۶۵] Shifted Windows

- این فرآیند باعث می‌شود که پیکسل‌ها در پنجره‌های مختلف (و در مرزهای مختلف) در محاسبات دخیل شوند و تبادل اطلاعات بهتری میان نواحی تصویر رخ دهد.

توجه چند سری پنجره ای

در توجه چندسری پنجره ای [۶۶]، نقشهٔ ویژگی به پنجره‌های $(M \times M)$ تقسیم می‌شود [۲۹]. هیچ جابه‌جایی در این تقسیم‌بندی وجود ندارد؛ یعنی اگر نقشهٔ ویژگی را یک مستطیل بزرگ در نظر بگیریم، آن را شبیه کاشی‌کاری یا شطرنج‌بندی به بلوک‌های مربعی $(M \times M)$ برش می‌زنیم. در این حالت، پیکسل‌های هر پنجره فقط با همدیگر (درون همان پنجره) ارتباط برقرار می‌کنند.

توجه چند سری پنجره ای جا به جا شده

مطابق شکل ؟؟، بعد از اینکه بلوک اول (توجه چند سری پنجره ای) کارش تمام شد، در بلوک دوم، قبل از تقسیم‌بندی به پنجره‌های $(M \times M)$، نقشهٔ ویژگی را جابه‌جا می‌کنیم [۲۹]. در مقالهٔ اصلی، این مقدار جابه‌جایی معمولاً نیمِ اندازهٔ پنجره $\frac{M}{2}$ در راستای افقی و عمودی است. به این ترتیب:

- پیکسل‌هایی که پیش از این در دو پنجرهٔ جداگانه قرار داشتند، ممکن است حالا به دلیل جابه‌جایی وارد یک پنجرهٔ مشترک شوند.
- مدل حالا می‌تواند بین این پیکسل‌های «مرزی» نیز توجه برقرار کند و اطلاعات را بهتر مبادله کند.

با این جابه‌جایی، بخشی از پیکسل‌ها در نقشهٔ ویژگی از یک طرف «خارج» می‌شوند. برای اینکه این پیکسل‌ها را از دست ندهیم، از ترفندی به نام جابجایی چرخه‌ای [۶۷] استفاده می‌شود. در جا به جایی چرخه ای ، پیکسل‌هایی که از سمت راست بیرون می‌روند دوباره از سمت چپ وارد می‌شوند

[۶۶] W-MSA
[۶۷] Cyclic Shift

و بالعکس؛ درست شبیه وقتی که یک تصویر را به‌صورت حلقه‌ای اسکرول می‌کنیم [۶۸]. مثالی از جا به جایی چرخه ای در شکل ۳.۱۱.۱۳ آمده است.

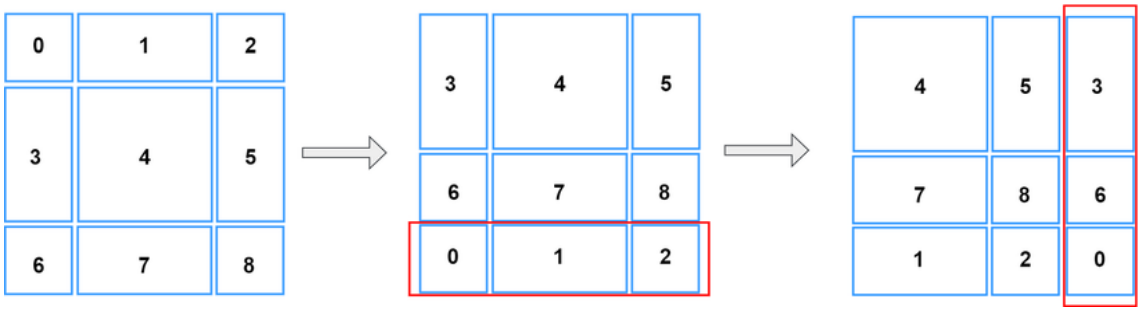


شکل ۳.۱۱.۱۳: جا به جایی چرخه ای

در بلوک اول (بدون جابه‌جایی)، پنجره‌ها ثابت‌اند و پیکسل‌های مرزی در هر پنجره ممکن است فرصت کافی برای تبادل اطلاعات با پیکسل‌های مرزیِ پنجرهٔ کناری را نداشته باشند.

در بلوک دوم (جابه‌جاشده)، مرزهای پنجره‌ها تغییر می‌کند و برخی پیکسل‌هایی که قبلاً در پنجره‌های جدا بودند، اکنون در یک پنجرهٔ مشترک‌اند؛ در نتیجه مدل می‌تواند رابطه و همبستگی بین آن‌ها را هم یاد بگیرد.

این جابه‌جایی و قرارگیری مجدد پیکسل‌ها کنار هم در نهایت کمک می‌کند تا مدل بتواند اطلاعات کل تصویر را با هزینهٔ محاسباتی کمتر (نسبت به توجهِ سراسریِ کامل) در اختیار داشته باشد [۲۹].

اگر بخواهیم با مثال توضیح دهیم، فرض کنید در یک تابلوی شطرنجی، خانه‌های کناری همدیگر را «نمی‌بینند» چون در دو بلوک مختلف هستند. اما اگر کمی تابلوی شطرنجی را به سمت بالا ــ چپ یا پایین ــ راست جابه‌جا کنیم، حالا بخشی از آن خانه‌ها وارد یک بلوک واحد می‌شوند و اطلاعاتشان با هم ترکیب می‌شود. سپس به‌طور دوره‌ای (*Cyclic*)، گوشه‌های اضافی را به آن سمت دیگر تابلوی شطرنجی می‌آوریم تا هیچ چیز از دست نرود.

[۶۸] Wrap around

به این شکل، سِری اول و دوم بلوک‌های مبدل های پنجره متحرک تکمیل‌کنندهٔ یکدیگر می‌شوند [۲۹]:

- بلوک اول: محاسبهٔ توجه در چهارچوب پنجره‌های ثابت.
- بلوک دوم: محاسبهٔ توجه در پنجره‌های جابه‌جاشده که منجر به تعامل بیشتر بین مرزهای مختلف می‌شود.

### ۶.۱۱.۳ پرسپتروون چند لایه

پس از انجام توجه چند سری پنجره ای جا به جا شده خروجی به یک مسیر **MLP** می‌رود [۲۹]. ساختار این MLP به‌صورت زیر است:

$$X' = \mathrm{GELU}(XW_1 + b_1)\, W_2 + b_2, \tag{۳.۱۱.۱۵}$$

که در آن

$$W_1 \in \mathbb{R}^{C\times(rC)}, \quad W_2 \in \mathbb{R}^{(rC)\times C}$$

هستند و $r$ معمولاً ضریب افزایش بعد را نشان می‌دهد (مثلاً ۴).

تابع فعال‌ساز GELU (یا ReLU و سایر توابع) نیز در این‌جا قابل استفاده است [۱۸].

### ۷.۱۱.۳ ترکیب پچ ها

در مدل مبدل های پنجره متحرک، ساختار سلسله‌مراتبی به این معناست که ما در چند مرحله (Stage) مختلف، نقشهٔ ویژگی را کوچک‌تر می‌کنیم و در عین حال، عمق (تعداد کانال‌های ویژگی) را افزایش می‌دهیم. هدف اصلی از این کار عبارت است از:

- استخراج ویژگی‌های سطح بالاتر: وقتی نقشهٔ ویژگی کوچک‌تر می‌شود، هر واحد از نقشهٔ ویژگی بیانگر بخش گسترده‌تری از تصویر اصلی است؛ پس مدل به‌تدریج جزئیات محلی را با درک کلی‌تری از تصویر جایگزین می‌کند [۱۷].

- کاهش هزینهٔ محاسبات: در مراحل بعدی، چون ابعاد فضایی کمتر می‌شود، مدل راحت‌تر می‌تواند با ویژگی‌های جدید کار کند (چون مثلاً به‌جای $(H \times W)$ پیکسل، تعداد کمتری پیکسل داریم) [۲۹].

این فرایند کوچک‌سازی در این مبدل با نام [۶۹] شناخته می‌شود که شبیه به در شبکه‌های کانولوشنی (مثل Pooling یا Stride-Convolution) عمل می‌کند.

[۲۹].

پس از چندین بلوک پردازشی، نقشهٔ ویژگی، ابعادی به شکل $(\frac{H}{P}, \frac{W}{P})$ با تعداد کانال $C$ دارد. این یعنی پس از برش‌دادن تصویر به پچ‌ها و گذر از چند لایه، اکنون یک نقشهٔ ویژگی داریم که کوچک‌تر از تصویر اصلی است، اما هنوز ممکن است خیلی بزرگ باشد.

در مرحلهٔ بعد (Stage بعدی)، می‌خواهیم این نقشه را نصف کنیم (یعنی طول و عرض را دو برابر کوچک کنیم) و در عوض عمق کانال را دو برابر کنیم (تا ظرفیت مدل در استخراج ویژگی‌های پیچیده‌تر بیشتر شود). برای انجام این کار از فرایندی به نام ترکیب پچ‌ها استفاده می‌کنیم.

[۲۹]:

۱. انتخاب بلوک‌های $(2 \times 2)$

ابتدا نقشهٔ ویژگی را در بُعد مکانی به بلوک‌های $(2 \times 2)$ تقسیم می‌کنیم. اگر $Z_{i,j}$ ویژگیِ مکان $(i, j)$ باشد، یک بلوک $(2 \times 2)$ شامل چهار پیکسل است:

$$Z_{2i,2j}, \quad Z_{2i,2j+1}, \quad Z_{2i+1,2j}, \quad Z_{2i+1,2j+1}.$$

[۶۹] Patch Merging

۲. ادغام ویژگی‌های چهار پیکسل

برای هر بلوک $(2 \times 2)$، این چهار پیکسل را در بُعد کانال به هم می‌چسبانیم. اگر هر پیکسل یک بردار از بعد $C$ باشد، اکنون بعدِ حاصل از کنار هم گذاشتن این چهار پیکسل می‌شود $4C$. نام این بردار ادغام‌شده را $Z'$ می‌گذاریم.

۳. لایهٔ خطی برای تغییر بعد

وقتی چهار بردار $C$ـ بعدی را کنار هم می‌گذاریم، یک بردار $4C$ـ بعدی شکل می‌گیرد. حال با یک لایهٔ خطی، بعدِ $4C$ را به بعد جدیدی تبدیل می‌کنیم. معمولاً این بعد جدید برابر $2C$ در نظر گرفته می‌شود؛ یعنی دو برابر بزرگ‌تر از قبل اما نه چهار برابر:

$$Z' \mapsto Z'' = Z' W_{\text{merge}} + b_{\text{merge}}, \qquad (۳.۱۱.۱۶)$$

که بعد ویژگی را از $4C$ به $2C$ کاهش می‌دهد.

۴. کاهش ابعاد مکانی

در عین حال، وقتی هر چهار پیکسل $(2\times2)$ را ادغام می‌کنیم، نقشهٔ ویژگی ما ابعاد فضایی $\left(\frac{H}{2P} \times \frac{W}{2P}\right)$ خواهد داشت (چون هر بلوک $(2 \times 2)$ تبدیل به یک بردار می‌شود).

به عبارت دیگر، تعداد نقاط مکانی نصف می‌شود (هم در طول و هم در عرض)، اما کانال از $C$ به $2C$ افزایش می‌یابد.

در شبکه‌های کانولوشنی، مرتبا از لایه‌های ادغام [۷۰] یا کانولوشن با گام [۷۱] برای کوچک‌کردن ابعاد استفاده می‌شود تا اطلاعات سطح بالاتر (مثل ساختار کلی اشیا) راحت‌تر استخراج شود [۱۷]. در مبدل پنجره متحرک هم همین ایدهٔ سلسله‌مراتب را به دنیای مبدل ها آورده است [۲۹]. همچنین اگر ابعاد فضایی را کم نکنیم، هزینهٔ توجه به‌شدت زیاد می‌شود (چون باید در هر لایه برای همهٔ پیکسل‌ها توجه محاسبه گردد).

[۷۰] Pooling
[۷۱] Stride-Convolution

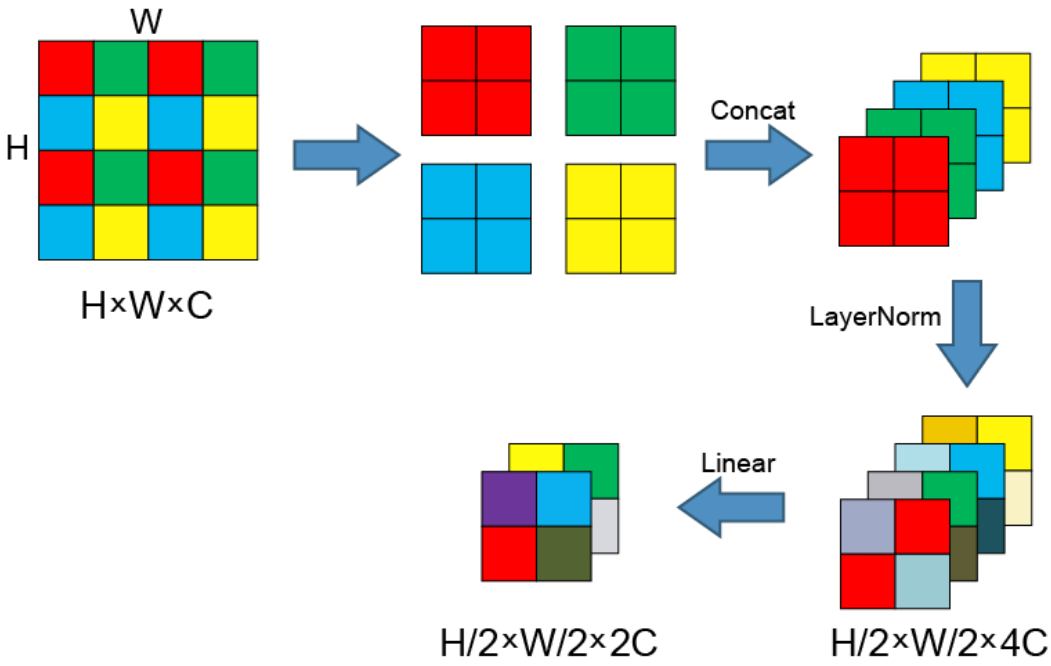


شکل ۳.۱۱.۱۴: ادغام پچ ها

در معماری کلی کبدل های پنجره متحرک، پس از Stage 1 و عبور از بلوک‌های W-MSA و SW-MSA، عملیات ادغام پچ ها انجام می‌شود. سپس در Stage 2، ویژگی‌های کوچک‌تری داریم، اما تعداد کانال‌ها افزایش یافته است [۲۹]. مشابه معماری‌های کانولوشنی، با افزایش عمق[۷۲]، ابعاد فضایی کاهش و تعداد کانال‌ها افزایش پیدا می‌کند.

در انتهای Stage آخر، خروجی به یک لایهٔ FC داده می‌شود تا تعداد کلاس‌ها را پیش‌بینی کند. پس از گذر از Softmax، احتمال هر کلاس به‌دست می‌آید و مدل در نهایت کلاس نهایی را برمی‌گزیند.

[۷۲] Depth

# فصل ۴

# پیشینه پژوهش

## تحلیل شبکه‌های ترانسفورمر و کانولوشن در پردازش تصاویر

در شبکه‌های ترانسفورمر، تصاویری که وارد شبکه می‌شوند، به پچ‌هایی با ابعاد مشخص تقسیم می‌شوند (مثل $8 \times 8$ یا $16 \times 16$ پیکسل). این پچ‌ها به عنوان ورودی به مدل داده می‌شوند، و در طی پردازش، مدل به طور عمومی این پچ‌ها را به صورت غیرمحلی [۱] و مستقل از مکان‌هایشان در تصویر پردازش می‌کند.

با این حال، در مدل‌های کانولوشن، ویژگی‌های محلی [۲] می‌توانند به راحتی شناسایی شوند چون شبکه به طور طبیعی در داخل تصویر حرکت کرده و ویژگی‌های اطراف یک نقطه خاص را تحلیل می‌کند. این ویژگی‌های محلی مثل لبه‌ها، بافت‌ها و اشیاء می‌توانند شناسایی شوند، زیرا هر فیلتر در یک ناحیه محلی از تصویر اعمال می‌شود و اطلاعات محلی را از آن ناحیه استخراج می‌کند.

اما در ترانسفورمرها، چون تصویر به پچ‌های ثابت تقسیم می‌شود و سپس این پچ‌ها به مدل وارد می‌شوند، دید محلی مدل محدود می‌شود. یعنی مدل نمی‌تواند به راحتی ویژگی‌های محلی تصویر را

[۱] Global
[۲] Local Features

مانند یک شبکه کانولوشنی شناسایی کند. به عبارت دیگر، مدل برای بررسی ارتباطات و ویژگی‌ها فقط با توجه به پچ‌های جداگانه و بدون آگاهی از ساختار کلی تصویر، عمل می‌کند.

در عین حال، ترانسفورمرها به دلیل ساختار توجه خود می‌توانند به روابط کلی نیز توجه داشته باشند. یعنی تمام پچ‌ها می‌توانند به هم متصل شوند و اطلاعاتی از نقاط دورتر تصویر را دریافت کنند. این ویژگی باعث می‌شود که مدل توانایی پردازش اطلاعات جهانی و تطبیق آن با سایر بخش‌های تصویر را داشته باشد.

اما این موضوع که ترانسفورمر نمی‌تواند به طور طبیعی دید محلی داشته باشد، به این معنی است که برخی از اطلاعات مفیدی که برای تحلیل دقیق تصاویر ضروری است، ممکن است از دست برود یا با مشکل مواجه شود. برای رفع این مشکل، معمولاً روش‌هایی مثل استفاده از لایه‌های کانولوشن در کنار ترانسفورمرها یا تقسیم‌بندی بهتر پچ‌ها به کار می‌رود تا شبکه قادر باشد هم دید محلی و هم دید گلوبال را به طور همزمان در اختیار داشته باشد.

### ۱.۰.۴ ویژگی‌های محلی

در شبکه‌های کانولوشن، فیلترهای کانولوشنی [۳] برای استخراج ویژگی‌های محلی طراحی شده‌اند. این فیلترها معمولاً روی نواحی کوچک تصویر (مانند $3 \times 3$ یا $5 \times 5$ پیکسل) اعمال می‌شوند. فرض کنید تصویری از یک گربه دارید؛ در لایه‌های ابتدایی یک کانولوشن، این فیلترها ممکن است لبه‌ها [۴]، گوشه‌ها [۵]، یا بافت‌های کوچک [۶] در موهای گربه را شناسایی کنند. این پردازش محلی است زیرا هر فیلتر فقط روی ناحیه کوچکی از تصویر تمرکز می‌کند.

[۳] Convolutional Filters
[۴] Edges
[۵] Corners
[۶] Textures

### ۲.۰.۴ ویژگی‌های جهانی

با عمیق‌تر شدن شبکه و افزایش تعداد لایه‌ها، خروجی لایه‌های ابتدایی (ویژگی‌های محلی) به ویژگی‌های بزرگ‌تر و پیچیده‌تر ترکیب می‌شوند. این فرآیند با استفاده از عملیات‌هایی مثل ادغام و فیلترهای بزرگ‌تر انجام می‌شود. برای مثال، پس از چند لایه، کانولوشن ممکن است به جای گوشه‌های گربه، ساختار کل گوش گربه را شناسایی کند. در لایه‌های عمیق‌تر، کانولوشن می‌تواند کل شکل گربه یا حتی دسته‌بندی نهایی (مانند اینکه این یک گربه است) را انجام دهد. این پردازش جهانی است زیرا کل تصویر را برای استنباط ویژگی‌های پیچیده در نظر می‌گیرد.

### ۳.۰.۴ مبدل ها و محدودیت‌های دید محلی

در ترانسفورمرها، ورودی تصویر به پچ‌های ثابت (مانند $16 \times 16$) تقسیم می‌شود و هر پچ به طور مستقل پردازش می‌شود، بدون آنکه ارتباطات بین پیکسل‌های داخل پچ یا بین پچ‌ها به‌صورت محلی در نظر گرفته شود. به عنوان یک مثال مشکل، اگر یک چشم گربه در مرز دو پچ جدا شود، مدل ممکن است این ارتباط محلی بین دو پچ را درک نکند و ویژگی چشم گربه از دست برود.

در ترانسفورمرها، ارتباطات بین پچ‌ها با استفاده از مکانیزم Self-Attention محاسبه می‌شود که به مدل اجازه می‌دهد ارتباطات گلوبال بین تمام پچ‌ها را بررسی کند، اما اغلب ویژگی‌های محلی نهفته در هر پچ نادیده گرفته می‌شوند.

برای حل مشکل دید local ، global ترانسفورمر ها، چند روش را پیاده کرده ایم

### ۴.۰.۴ روش اول:

### ۵.۰.۴ تبدیل تصاویر به دو پچ مجزا:

فرض کنید تصویری با اندازهٔ $224 \times 224$ پیکسل داریم که اندازه‌ای متداول در دیتاست‌هایی نظیر ImageNet است. این تصویر به دو صورت مختلف به پچ‌هایی با اندازه‌های متفاوت تقسیم

می‌شود.

در روش اول، تصویر به بلوک‌هایی با ابعاد $8 \times 8$ پیکسل تقسیم می‌شود. در این حالت، تعداد پچ‌ها در هر ردیف و ستون به ترتیب برابر با 28 است و در مجموع

$$28 \times 28 \ = \ 784$$

پچ از تصویر استخراج می‌شود. هر پچ شامل $8 \times 8$ پیکسل است و اگر تصویر دارای سه کانال رنگی باشد (مانند تصاویر RGB)، هر پچ شامل

$$8 \times 8 \times 3 \ = \ 192$$

مقدار عددی خواهد بود. این پچ‌ها پس از تبدیل به بردار، به عنوان ورودی به یکی از مسیرهای پردازشی در ترانسفورمر وارد می‌شوند.

ویک بار دیگر همان تصویر به بلوک‌هایی با ابعاد $16 \times 16$ پیکسل تقسیم می‌شود. در این حالت، تعداد پچ‌ها در هر ردیف و ستون به ترتیب 14 است و در مجموع

$$14 \times 14 \ = \ 196$$

پچ ایجاد می‌شود. هر پچ $16 \times 16$ پیکسل را شامل می‌شود و در صورت RGB بودن تصویر، هر پچ دارای

$$16 \times 16 \times 3 \ = \ 768$$

مقدار عددی خواهد بود. این پچ‌ها نیز به بردار تبدیل شده و به مسیر پردازشی جداگانه‌ای در ترانسفورمر وارد می‌شوند.

بنابراین در همان ابتدا ما دو تا لایه موازی را در ترانسفورمر پیش میگیریم یکی با دید جزئی و یکی هم با دیدگاه جهانی و در ادامه این دید های جزئی و جهانی را با یک دیگر ترکیب میکنیم اما قبل آن باید یک سری کار ها برای انجام این کار صورت گیرد.

### ۶.۰.۴ هماهنگ سازی پچ ها:

در این مرحله، هدف آن است که پس از لایه‌های اولیهٔ ترانسفورمر (یا هر مرحله‌ای که پچ‌های $8 \times 8$ و $16 \times 16$ جاسازی اولیه شده‌اند)، تعداد و ترتیب پچ‌های هر دو مسیر را هماهنگ کنیم تا امکان ادغام (ترکیب) آن‌ها در لایه‌های بعدی فراهم شود. دو عمل مهم در این بخش اتفاق می‌افتد:

۱. تکرار (Replication) پچ‌های $16 \times 16$ به تعداد ۴ برابر

۲. تغییر ترتیب (Re-Order) پچ‌های $8 \times 8$

این دو گام باعث می‌شوند در نهایت، هر دو مجموعهٔ پچ، دارای ۷۸۴ ردیف (پچ) باشند و ردیف‌های متقابل در هر دو مجموعه، به ناحیهٔ فضایی یکسانی از تصویر اصلی اشاره کنند. در ادامه، هر یک از این مراحل را با جزئیات بیشتری توضیح می‌دهیم.

## تکرار ۴ برابری پچ‌های $16 \times 16$

چرا باید تعداد پچ‌های $16 \times 16$ را ۴ برابر کنیم؟

اگر تصویر ورودی $224 \times 224$ باشد، پچ‌های $16 \times 16$ در هر بعد

$$\frac{224}{16} = 14$$

قطعه تولید می‌کنند و بنابراین در کل،

$$14 \times 14 = 196$$

پچ خواهیم داشت. در مقابل، پچ‌های $8 \times 8$ به‌خاطر نصف‌بودن ضلع پچ (8 به‌جای 16)، تعداد قطعات در هر بعد دو برابر می‌شود:

$$\frac{224}{8} = 28.$$

پس تعداد کل پچ‌ها

$$28 \times 28 = 784$$

خواهد بود. واضح است که

$$784 = 4 \times 196.$$

یعنی پچ‌های $8 \times 8$ چهار برابر بیشتر از پچ‌های $16 \times 16$ هستند.

چون قصد داریم در گامی بعدی (مثلاً یک لایه انکودر مشترک) این دو مجموعهٔ پچ را ادغام یا مقایسه کنیم، باید تعداد پچ‌های هر دو مسیر یکسان باشد.

## مکانیزم تکرار

برای هم‌اندازه‌کردن این دو مجموعه، هر پچ $16 \times 16$ را دقیقاً چهار بار کپی می‌کنیم. به صورت ریاضی، اگر

$$X^{(16\times16)} \in \mathbb{R}^{196\times D}$$

ماتریسی در ابعاد $196 \times D$ باشد (یعنی ۱۹۶ پچ، هر کدام برداری با بعد $D$)، عمل تکرار به شکل زیر نوشته می‌شود:

$$\tilde{X}^{(16\times16)} = \underbrace{\left[X^{(16\times16)}, X^{(16\times16)}, X^{(16\times16)}, X^{(16\times16)}\right]}_{\text{تکرار ۴ مرتبه}} \in \mathbb{R}^{784\times D}.$$

عملگر $[\cdot]$ در این‌جا به معنای الحاق (Concatenate) در راستای بُعد اول (تعداد پچ‌ها) است. در نتیجه، ۴ نسخهٔ یکسان از $X^{(16\times16)}$ پشت سر هم قرار می‌گیرند و ابعاد نهایی به $784 \times D$ می‌رسد.

از نظر مفهومی، چنین برداشتی وجود دارد که هریک از پچ‌های $16 \times 16$، وقتی روی تصویر اصلی نگاه کنیم، با چهار منطقهٔ کوچک‌تر $8 \times 8$ هم‌پوشانی دارد (چون $16 \times 16$ ازلحاظ مساحت ۴ برابر $8 \times 8$ است). اما فعلاً صرفاً از نظر تعداد، آن را ۴ مرتبه تکرار می‌کنیم؛ بعداً در مرحلهٔ «تغییر ترتیب» توضیح می‌دهیم که چگونه می‌توان این تکرار را به بخش‌های تصویر ربط داد.

## تغییر ترتیب (Re-Order) پچ‌های $8 \times 8$

اکنون که پچ‌های $16 \times 16$ به‌صورت ۴ برابر تکرار شده و به ۷۸۴ پچ رسیده‌اند، می‌خواهیم پچ‌های $8 \times 8$ را نیز به شکلی بازآرایی کنیم که هر گروه ۴تایی از پچ‌های $8 \times 8$ دقیقاً متناظر با یک پچ $16 \times 16$ باشد. این متناظر بودن از نظر موقعیت مکانی در تصویر اهمیت دارد.

چرا بازآرایی (Re-Order) لازم است؟

در استخراج اولیهٔ پچ‌های $8 \times 8$، معمولاً طبق یک ترتیب خطی (مانند Row-Major) از گوشهٔ بالا ـ چپ تصویر تا گوشهٔ پایین ـ راست حرکت می‌کنیم و پچ‌ها را شماره‌گذاری می‌کنیم (۱، ۲، ۳، ... ۷۸۴). در این شماره‌گذاری عادی، پچ‌های ۱، ۲، ۳ و ۴ لزوماً در کنار هم قرار دارند، اما این هم‌جواری ممکن است دقیقاً با پچ اولِ $16 \times 16$ منطبق نباشد.

برای مثال، ممکن است پچ ۱ در $8 \times 8$ با پیکسل‌های ردیف ۰ تا ۷ و ستون ۰ تا ۷ هم‌پوشانی داشته باشد، درحالی‌که پچ ۲ در $8 \times 8$ مربوط به ردیف ۰ تا ۷ و ستون ۸ تا ۱۵ است. اگر بگوییم پچ اولِ $16 \times 16$ (که کل ناحیهٔ صفر تا ۱۵ در سطر و صفر تا ۱۵ در ستون را می‌پوشاند) با ۴ پچ $8 \times 8$ متناظر است، لازم است به‌درستی تشخیص دهیم که آن ۴ پچ در کدام شماره‌های ۱ تا ۷۸۴ قرار گرفته‌اند. برای مثال (در یک چینش فرضی):

- پچ‌های (۱، ۲، ۲۹، ۳۰) از میان $8 \times 8$ احتمالاً چهار بخش کوچکی هستند که روی‌هم پیکسل‌های سطر ۰..۱۵ و ستون ۰..۱۵ را می‌پوشانند. پس این ۴ پچ باهم معادل پچ اولِ $16 \times 16$ هستند.

- پچ دومِ $16 \times 16$ ممکن است با پچ‌های (۳، ۴، ۳۱، ۳۲) در $8 \times 8$ هم‌پوشانی داشته باشد، و به همین شکل ادامه می‌یابد.

بنابراین برای اینکه «ردیف اول تکرارشدهٔ پچ $16 \times 16$» با «۴ ردیف درست از پچ‌های $8 \times 8$» روبه‌رو شود، باید ترتیب پچ‌های $8 \times 8$ دقیقاً طبق این نقشهٔ فضایی بازآرایی (Re-Order) شود.

تابع ReOrder

به‌صورت ریاضی، می‌توان این بازآرایی را به شکل یک تابع $\mathrm{ReOrder}(\cdot)$ نشان داد. اگر

$$X^{(8\times 8)} \in \mathbb{R}^{784\times D}$$

ماتریسی با ابعاد $784 \times D$ باشد (شماره‌گذاری ردیفی عادی)، خروجی زیر را خواهیم داشت:

$$\hat{X}^{(8\times 8)} \;=\; \mathrm{ReOrder}\big(X^{(8\times 8)}\big) \;\in\; \mathbb{R}^{784\times D}.$$

وظیفهٔ ReOrder آن است که ردیف‌های $X^{(8\times 8)}$ را طوری جابه‌جا کند که ۴ ردیف پشت‌سرهم در $\hat{X}^{(8\times 8)}$ دقیقاً همان چهار بخشی از تصویر باشند که یک پچ خاص $16 \times 16$ (در حالت تکرارشده) روی آن قرار دارد. به‌عبارت دیگر، از ۱، ۲، ۳، ۴ در چینش عادی، ممکن است تبدیل به ۱، ۲، ۲۹، ۳۰ شود (اگر چنین ترتیبی در صفحهٔ تصویر باهم منطبق است).

### ۷.۰.۴ Positional Embedding

در این مرحله که هماهنگ‌سازی پچ‌ها (Alignment Patch) به اتمام رسیده و هر دو مجموعهٔ پچ (مسیر $8 \times 8$ و مسیر $16 \times 16$ تکرارشده) دارای ابعاد یکسان $(784 \times D)$ و ترتیب متناظر هستند، می‌توان جاسازی مکانی (Embedding Positional) را اعمال کرد. هدف از افزودن Positional Embedding آن است که مدل بتواند جایگاه هر پچ در تصویر اصلی را درک کند و صرفاً با بردارهای ویژگی انتزاعی مواجه نباشد.

اغلب در مدل‌های ترانسفورمر بینایی، برای هر پچ (صرف‌نظر از اندازه‌اش) یک بردار مکان (Embedding Position) پیش‌بینی می‌شود که در همان ابتدای مسیر با بردار ویژگی پچ جمع می‌گردد. اما در رویکرد فعلی، چون ما ابتدا لازم داشتیم پچ‌های $16 \times 16$ را تکرار کنیم و پچ‌های $8\times 8$ را تغییر ترتیب بدهیم، بهتر است پس از این بازآرایی، Embedding Positional را به‌گونه‌ای اعمال کنیم که دقیقاً منعکس‌کنندهٔ جایگاه نهایی هر پچ در ترتیب هماهنگ‌شده باشد.

در غیر این صورت، اگر قبل از هماهنگی، Embedding Positional اعمال شده بود، تکرار و جابه‌جایی پچ‌ها ممکن است ساختار مکان‌یابی آن‌ها را به‌هم بریزد یا نیاز به به‌روزرسانی مجدد Embedding Position باشد.

از آنجا که هر دو مجموعهٔ پچ ($8 \times 8$ و $16 \times 16$ تکرارشده) پس از هماهنگ‌سازی در ابعاد $\mathbb{R}^{784\times D}$ هستند، ماتریس جاسازی مکانی ($E_{\text{pos}}$) نیز باید ۷۸۴ سطر داشته باشد. در نتیجه:

$$E_{\text{pos}} \in \mathbb{R}^{784\times D},$$

که در آن هر سطر از $E_{\text{pos}}$ مختص یک پچ (ردیف) در خروجی مرحلهٔ هماهنگ‌سازی است.

در این روش، تنها از یک مجموعهٔ $E_{\text{pos}}$ مشترک برای هر دو نوع پچ استفاده می‌شود. جون هر دو ابعاد یکسان هستند و embedding positional پارامتر یادگیرنده ندارد میتوان از یک positional embedding استفاده کرد.

### ۸.۰.۴ لایه های اول تا هشتم انکودر

پس از آنکه Embedding Positional به پچ‌های هر دو مسیر اعمال شد، عملاً هر دو مجموعهٔ خروجی دارای شکل و ابعاد یکسان ($784 \times D$) هستند (در این مرحله فرض گرفته‌ایم token CLS وجود نداشته باشد یا در محاسبات فعلی نادیده گرفته شود). این امر باعث می‌شود که در هر دو مسیر، Query، Key و Value در مکانیزم Self-Attention نیز ابعاد یکسانی داشته باشند.

### ۹.۰.۴ لایه نهم انکودر

در لایهٔ نهم، ابتدا Query و Key را برای هر مسیر به‌صورت جداگانه محاسبه می‌کنیم. طبق روال استاندارد ترانسفورمر، هر ورودی با ماتریس‌های وزنیِ یادگیری‌پذیر ($W_Q$ و $W_K$) ضرب می‌شود تا به فضاهای $Q$ و $K$ نگاشت شود. بسته به طراحی، می‌توان از همان وزن‌ها یا وزن‌های جداگانه استفاده کرد؛ اما برای سادگی، فرض کنیم وزن‌ها مشترک هستند:

$$Q^{(8)} = X^{(8)}W_Q, \quad K^{(8)} = X^{(8)}W_K,$$

$$Q^{(16)} = X^{(16)}W_Q, \quad K^{(16)} = X^{(16)}W_K.$$

هرکدام از $Q^{(8)}$ و $Q^{(16)}$ ابعادی معادل $\mathbb{R}^{784\times d_k}$ دارند ($d_k$ معمولاً $\frac{D}{h}$ در صورت چندسری بودن Attention است، یا ممکن است با $D$ برابر باشد در صورت تک‌سری).

به‌طور مشابه $K^{(8)}$ و $K^{(16)}$ نیز ابعادی معادل $\mathbb{R}^{784\times d_k}$ دارند.

### ۱۰.۰.۴ محاسبهٔ ماتریس شباهت ($QK^T$) و میانگین‌گیری

مکانیزم خودتوجهی (Self-Attention) معمولاً از ضرب $Q$ در $K^T$ برای محاسبهٔ میزان شباهت پچ‌ها استفاده می‌کند. شما می‌خواهید قبل از Softmax، میانگین شباهت‌های دو مسیر را بگیرید. بنابراین به این ترتیب عمل می‌کنیم:

#### شباهت مسیر $8 \times 8$:

$$S^{(8)} = Q^{(8)}K^{(8)^T} \in \mathbb{R}^{784\times 784}$$

#### شباهت مسیر $16 \times 16$:

$$S^{(16)} = Q^{(16)}K^{(16)^T} \in \mathbb{R}^{784\times 784}$$

#### ادغام شباهت‌ها:

سپس برای ادغام این دو شباهت، از میانگین‌گیری استفاده می‌کنیم:

$$S_{\text{merged}} = \frac{S^{(8)} + S^{(16)}}{2}.$$

در هر دوی $S^{(8)}$ و $S^{(16)}$ ابعاد $\mathbb{R}^{784\times 784}$ دارند و بنابراین جمع‌کردن و میانگین‌گیری آن‌ها بدون مشکل صورت می‌گیرد.

### ۱۱.۰.۴ اعمال مقیاس‌بندی $\frac{1}{\sqrt{d_k}}$ و Softmax

در نسخهٔ کلاسیک Attention، ماتریس شباهت $QK^T$ معمولاً با ضریب $\frac{1}{\sqrt{d_k}}$ مقیاس (Scaling) می‌شود تا مقادیر بزرگ در ماتریس شباهت کنترل شوند و یادگیری پایدارتر شود:

$$\tilde{S}_{\text{merged}} = \frac{1}{\sqrt{d_k}} S_{\text{merged}} = \frac{1}{\sqrt{d_k}} \cdot \frac{S^{(8)} + S^{(16)}}{2} = \frac{S^{(8)} + S^{(16)}}{2\sqrt{d_k}}.$$

در گام بعدی، باید بر روی هر سطر این ماتریس $\tilde{S}_{\text{merged}}$ عمل Softmax انجام دهیم تا ضرایب توجه ($A$) به دست آید:

$$A = \text{softmax}(\tilde{S}_{\text{merged}}) \ \in \ \mathbb{R}^{784\times 784}.$$

به‌عبارت دیگر، برای هر عنصر $A_{ij}$:

$$A_{ij} = \frac{\exp(\tilde{S}_{\text{merged},ij})}{\sum_{k=1}^{784} \exp(\tilde{S}_{\text{merged},ik})}$$

این ماتریس $A$ نشان‌دهندهٔ وزن‌های توجه بین هر دو پچ است. در اینجا:

- سطرها نشان‌دهندهٔ پچ‌های Query هستند.
- ستون‌ها نشان‌دهندهٔ پچ‌های Key هستند.

در این مرحله، خروجی نهایی مکانیزم توجه (Attention) تنها بر اساس بردارهای $V$ مربوط به پچ‌های $8 \times 8$ تولید می‌شود. در معماری استاندارد ترانسفورمر، پس از محاسبهٔ نقشهٔ توجه $\text{softmax}(QK^T)$، نتیجه در بردارهای ارزش ($V$) ضرب می‌گردد تا بردار نهایی توجه به دست آید:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V.$$

اما ما در اینجا از بردارهای $V$ صرفاً متعلق به مسیر پچ‌های $8 \times 8$ استفاده می‌شود. برای این منظور، ابتدا با استفاده از ماتریس وزنی $W_V$، بردار ارزش $V^{(8)}$ را از $X^{(8)}$ (بردار ویژگی پچ‌های $8 \times 8$) استخراج می‌کنیم:

$$V^{(8)} = X^{(8)} W_V \ \in \ \mathbb{R}^{784\times d_v},$$

که در آن $W_V$ یک ماتریس یادگیری‌پذیر با ابعاد $D \times d_v$ است.

پس از آن‌که نقشهٔ توجه نهایی $A$ (محاسبه‌شده بر پایهٔ ترکیب میانگین‌شده از شباهت‌های مربوط به مسیرهای $8 \times 8$ و $16 \times 16$) شکل گرفت، خروجی مکانیزم توجه ($O_{\text{Attention}}$) با ضرب $A$ در $V^{(8)}$ حاصل می‌شود:

$$O_{\text{Attention}} = AV^{(8)} = \text{softmax}\left(\frac{S^{(8)} + S^{(16)}}{2\sqrt{d_k}}\right) V^{(8)},$$

که در آن:

$$A = \text{softmax}\left(\frac{S^{(8)} + S^{(16)}}{2\sqrt{d_k}}\right),$$

و:

$$S^{(8)} = Q^{(8)} K^{(8)^T}, \quad S^{(16)} = Q^{(16)} K^{(16)^T}.$$

با جای‌گذاری کامل، فرمول زیر به‌دست می‌آید:

$$O_{\text{Attention}} = \text{softmax}\left(\frac{1}{2\sqrt{d_k}}\left(Q^{(8)} K^{(8)^T} + Q^{(16)} K^{(16)^T}\right)\right) V^{(8)}.$$

## مزیت این رویکرد

به این ترتیب:

- وزن‌های توجه ($A$) از ترکیب میانگین‌شدهٔ شباهت‌های دو مسیر (اطلاعات محلی از پچ‌های کوچک و اطلاعات کلی از پچ‌های بزرگ) به دست می‌آید.
- بردار ارزش ($V$) تنها از مسیر پچ‌های $8 \times 8$ استخراج می‌شود.

این روش باعث می‌شود ویژگی‌های محلی (که در $V^{(8)}$ متمرکز هستند) مستقیماً در خروجی نهایی منعکس شوند، اما وزن‌دهی به این ویژگی‌ها تحت تأثیر هر دو نما (محلی و کلی) انجام گیرد. به بیان دیگر، با وجود آن‌که اطلاعات ارزش از مسیر ریزدانه انتخاب می‌شود، مکانیزم توجه نقشهٔ

شباهت خود را از ادغام دو مقیاس به دست می‌آورد. این رویکرد می‌تواند توازنی مطلوب میان جزئی‌نگری و شناخت ساختار وسیع‌تر تصویر برقرار سازد.

### ۱۲.۰.۴ ادغام وزنی

به‌جای آنکه شباهت‌های مربوط به پچ‌های $8 \times 8$ و $16 \times 16$ را به شکل مساوی (ضریب $\frac{1}{2}$) با هم جمع کنیم، می‌توان از پارامتری یادگیری‌پذیر (parameter trainable) به‌نام $\alpha$ استفاده کرد که در بازهٔ $[0, 1]$ قرار دارد. فرمول ترکیب ماتریس شباهت‌ها ($S^{(8)}$ و $S^{(16)}$) به‌شکل زیر تغییر می‌کند:

$$S_{\text{merged}} = \alpha S^{(8)} + (1 - \alpha) S^{(16)}.$$

#### تأثیر مقدار $\alpha$ در مدل

- اگر $\alpha$ به‌سمت ۱ متمایل شود، نقش پچ‌های $8 \times 8$ در توجه مدل پررنگ‌تر خواهد شد.
- اگر $\alpha$ کوچک باشد، توجه بیشتری به پچ‌های $16 \times 16$ اختصاص داده می‌شود.

با استفاده از پارامتر $\alpha$ انعطاف پذیری مدل به صورت قابل توجه ای افزایش پیدا میکند.

#### آموزش پارامتر $\alpha$

خود مدل در فرایند آموزش با پس‌انتشار خطا (Back-Propagation) می‌تواند مقدار بهینهٔ $\alpha$ را بیاموزد. این انعطاف‌پذیری به مدل اجازه می‌دهد تا به‌طور خودکار تعادلی میان اطلاعات جزئی (از پچ‌های کوچک‌تر) و اطلاعات کلی (از پچ‌های بزرگ‌تر) برقرار کند.

## ۱.۴ روش دوم sampling: down

در sampling down پس از چند مرحله پردازش (بلوک‌های ترنسفورمر)، حجم توکن‌های پچ را به شکل مؤثری کاهش دهیم تا هم هزینه‌ی محاسباتی (به‌ویژه در عملیات توجه چندسری) کمتر

شود و هم مدل به‌تدریج بتواند از حالت توجه به جزییات ریز (ویژگی‌های محلی) به نمایی کلی‌تر از تصویر (ویژگی‌های کلی) برسد.

در این مدل ما token cls را تا انتها دست نخورده باقی میگذاریم.

پس از عبور تصویر از مرحله‌ی پَچ‌گذاری Patch) (Embedding و الحاق توکن [CLS] ، تعداد توکن‌ها در ابتدا به‌صورت:

$$N = 1 + 784 = 785 \tag{۴.۱.۱}$$

در نظر گرفته می‌شود. در این رابطه، عدد 784 بیانگر تقسیم‌بندی یک تصویر $224 \times 224$ به پچ‌های $8 \times 8$ (یعنی $28 \times 28 = 784$ پچ) و عدد 1 توکن ویژه‌ی [CLS] است. همچنین بعدِ ویژگی هر توکن (شامل پچ‌ها و [CLS]) برابر با 768 خواهد بود. ازاین‌رو، شکل ورودی در شروع کار:

$$(B, 785, 768) \tag{۴.۱.۲}$$

است که $B$ اندازه‌ی بچ Batch) (Size محسوب می‌شود.

در حالت نرمال در ترانسفورمرها اندازه ورودی اتنشن ها در بلوک های انکودر تغییری نمیکنند.

روش دانسمپلینگ جفتی بر این ایده استوار است که توکن [CLS] (ابتدای توالی) دست‌نخورده باقی بمانَد و سایر توکن‌ها (نماینده‌ی پچ‌ها) را دوتادوتا با هم میانگین بگیریم. اگر ورودی ما

$$(B, N, 768) \tag{۴.۱.۳}$$

باشد و در آن $N - 1$ توکن پچ وجود داشته باشد، آنگاه با جفت‌کردن و میانگین‌گیری پچ‌ها، تعداد نهایی از رابطه‌ی

$$N_{new} = 1 + \frac{N-1}{2} = \frac{N+1}{2} \tag{۴.۱.۴}$$

به‌دست می‌آید. توکن [CLS] همچنان در موقعیت اول باقی می‌مانَد و ابعاد ویژگی (یعنی 768) تغییری نمی‌کند.

بنابراین، پس از بلوک سوم که همچنان ورودی $(B, 785, 768)$ دارد و خروجی همان $(B, 785, 768)$ را تولید می‌کند، با اجرای دانسمپلینگ جفتی تعداد توکن‌ها از 785 به $1 + \frac{784}{2} = 393$ کاهش می‌یابد؛ درنتیجه ورودی بلوک بعدی $(B, 393, 768)$ خواهد بود.

و همین کار پس از بلوک انکودر ششم و نهم اعمال می شود. و همینطور ورودی انکودر بعدی کم و کم تر میشود.

به‌طور خلاصه، ابعاد ورودی هر بلوک پس از آنکه دانسمپلینگ در انتهای بلوک‌های ۳، ۶ و ۹ اعمال شود، بدین ترتیب تغییر می‌کند:

$$(B, 785, 768) \xrightarrow{\text{بلوک ۳ + دانسمپلینگ}} (B, 393, 768),$$

$$(B, 393, 768) \xrightarrow{\text{بلوک ۶ + دانسمپلینگ}} (B, 197, 768),$$

$$(B, 197, 768) \xrightarrow{\text{بلوک ۹ + دانسمپلینگ}} (B, 99, 768).$$

### ۱.۱.۴ حرکت تدریجی از جزئیات به کلیت

در لایه‌های اولیه، وقتی هنوز دانسمپلینگ انجام نشده، مدل همهٔ پچ‌های ریز و «اطلاعات محلی» را در اختیار دارد و مسسسی‌تواند ویژگی‌های ظریف را پردازش کند. اما وقتی چند لایه گذشت و وارد بلوک‌های بالاتر شدیم، با اعمال میانگین‌گیری جفتی، اطلاعات هر دو پچ مجاور در یک بردار ادغام می‌شود. این وضعیت را می‌توان شکل‌گیری نوعی «نمای کلی‌تر» از تصویر دانست؛ زیرا به‌جای ۲ پچ مجزا، حالا یک پچ ترکیبی داریم که اطلاعاتشان را در خود گنجانده است. به این ترتیب، مدل در سطوح بالاتر روی ویژگی‌های انتزاعی‌تر یا خلاصه‌تر متمرکز می‌شود و نیازی نیست همچنان هزینه‌ی نگه‌داشتن تمام جزئیات محلی را بپردازد.

### ۲.۱.۴ کم نشدن پارامتر ها در این مدل

در معماری‌های ترنسفورمر، پارامترهای قابل یادگیری تنها به شکل وزن‌ها و بایاس‌هایی تعریف می‌شوند که یا در مرحله‌ی تعبیه‌سازی ،(Embedding) یا در بخش توجه چندسری، یا در شبکه‌های MLP هر بلوک ترنسفورمر به‌کار می‌روند. نکته‌ی کلیدی این است که ابعاد اغلب این وزن‌ها و بایاس‌ها تنها به بُعد پنهان (Hidden Dimension) یا نرخ گسترش (Expansion Ratio) وابسته است و تغییری در آن‌ها به تناسب کم یا زیاد شدن تعداد توکن‌های ورودی به وجود نمی‌آید.

لایه‌های تعبیه‌ساز و موقعیتی (Positional Embedding) ابتدا در این بخش، پارامترها به‌صورت ماتریس‌ها یا بردارهایی تعریف می‌شوند که بُعد آن‌ها با بُعد پنهان (مثلاً ۷۶۸) تنظیم می‌شود و همچنین به طول حداکثری توالی وابستگی دارد (مثلاً اگر حداکثر تعداد توکن ۷۸۵ در نظر گرفته شود، در همان ابتدای تعریف پارامتر شکل می‌گیرد). در هر صورت، این پارامترها فارغ از آن که در عمل چند توکن مؤثر باقی بماند، ثابت خواهند ماند.

توجه چندسری (Multi-Head Attention) در این بخش، ماتریس‌های $W_Q$، $W_K$، $W_V$ و $W_O$ موجودند که ابعادشان همگی تابعی از بُعد ویژگی $D$ هستند؛ برای مثال اگر $D = 768$ باشد، هر کدام از این ماتریس‌ها در ابعاد ثابتی (مانند $768 \times 768$) تعریف شده و یاد گرفته می‌شود. این پارامترها به «تعداد توکن» بستگی ندارند؛ بلکه تعیین می‌کنند چگونه هر توکن در فضای ویژگی (Feature Space) نگاشت یا پردازش شود.

شبکه‌های MLP داخل هر بلوک ترنسفورمر در این بخش، وزن‌ها و بایاس‌ها به‌صورت $W_1, b_1$ و $W_2, b_2$ تعریف می‌شوند. ابعاد این لایه‌ها عموماً از قانون

$$D \to 4D \to D$$

پیروی می‌کند (اگر نسبت گسترش ۴ باشد). در نتیجه، شکل $W_1$ و $W_2$ هم تنها وابسته به $D$ است. تعداد کم یا زیاد شدن توکن‌ها (مثلاً نصف‌شدن توکن‌ها پس از دانسمپلینگ) صرفاً بر روی تعداد محاسبات اثر می‌گذارد، اما ساختار و تعداد این پارامترها را دگرگون نمی‌کند.

در یک لایهٔ ترنسفورمر، مهم‌ترین قسمت از نظر هزینه، محاسبهٔ Self-Attention است. اگر تعداد توکن‌ها را $N_{\text{tokens}}$ بنامیم و فرض کنیم بعد بردار ویژگی‌ها $D$ باشد، آنگاه مهم‌ترین بخش محاسباتی مربوط به ضرب ماتریسی $QK^\top$ است که پیچیدگی زمانی $O(N_{\text{tokens}}^2 \cdot D)$ دارد.

وقتی دانسمپلینگ جفتی انجام می‌دهیم و تعداد توکن‌ها را از $N_{\text{tokens}}$ به حدود $\frac{N_{\text{tokens}}}{2}$ کاهش می‌دهیم، پیچیدگی زمانی در لایه‌های بعدی به شکل زیر تغییر می‌کند:

$$O(N_{\text{tokens}}^2 \cdot D) \quad \longrightarrow \quad O\left(\left(\frac{N_{\text{tokens}}}{2}\right)^2 \cdot D\right) \longrightarrow O\left(\frac{N_{\text{tokens}}^2}{4} \cdot D\right).$$

و به این ترتیب حجم محاسبات به شکل چشم گیری کم میشود.

# فصل ۵

# آزمایشات و نتایج

# کتاب‌نامه


[1] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016. 34, 35

[2] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In *Proceedings of the 2015 International Conference on Learning Representations (ICLR)*, San Diego, CA, 2015. 21, 23, 24, 37, 38

[3] Yoshua Bengio et al. *Learning long-term dependencies with gradient descent is difficult.* IEEE Transactions on Neural Networks, 1994. 32, 33

[4] Christopher M. Bishop. *Pattern Recognition and Machine Learning.* Springer, New York, 2006. 6, 7, 10, 11, 12

[5] Peter F Brown, Vincent J. Della Pietra, Stephen A. Della Pietra, and Robert L Mercer. The mathematics of statistical machine translation: Parameter estimation. *Computational linguistics*, 19(2):263–311, 1993. 24

[6] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995. 10

[7] Thomas M. Cover and Peter E. Hart. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27, 1967. 9

[8] Daniel Crevier. *AI: The Tumultuous History of the Search for Artificial Intelligence.* Basic Books, New York, 1993. 4, 5

[9] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018. 23, 45, 46

[10] Pedro Domingos and Michael Pazzani. On the optimality of the simple bayesian classifier under zero-one loss. *Machine Learning*, 29(2–3):103–130, 1997. 11

[11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, et al. An image is worth 16x16 words: Transformers for image recognition at scale, 2020. 39, 40, 43, 44, 45, 46, 47, 48, 49

[12] Richard O. Duda and Peter E. Hart. *Pattern Classification and Scene Analysis*. John Wiley & Sons, New York, 1973. 9

[13] Jeffrey L. Elman. Finding structure in time. *Cognitive Science*, 14(2):179–211, 1990. 13, 24, 28

[14] Edward A. Feigenbaum and Pamela McCorduck. *The Fifth Generation: Artificial Intelligence and Japan's Computer Challenge to the World*. Addison-Wesley, Reading, MA, 1983. 4, 5

[15] Felix A. Gers, Jürgen Schmidhuber, and Fred Cummins. Learning to forget: Continual prediction with lstm. In *Proceedings of the Ninth International Conference on Artificial Neural Networks (ICANN-99)*, pages 850–855, Edinburgh, UK, 1999. 12, 14, 16, 17, 19

[16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, Cambridge, MA, 2016. 6, 13, 14, 15, 19, 20

[17] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016. 33, 40, 47, 48, 56, 57

[18] Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv:1606.08415*, 2016. 55

[19] Sepp Hochreiter. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(2):107–116, 1998. 14, 15, 18, 20

[20] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. 12, 14, 15, 16, 19, 28, 32, 33

[21] John Hutchins. *Machine translation: past, present, future*. Ellis Horwood Chichester, 1986. 24

[22] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International conference on machine learning*, pages 448–456, 2015. 34, 35

[23] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning: with Applications in R*. Springer, New York, 2013. 7, 9

[24] Philipp Koehn. *Statistical Machine Translation*. Cambridge University Press, 2010. 24

[25] Philipp Koehn, Franz Josef Och, and Daniel Marcu. Statistical phrase-based translation. In *Proc. of NAACL/HLT*, pages 48–54, 2003. 24

[26] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012. 40

[27] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. 40

[28] James Lighthill. *Artificial Intelligence: A General Survey*. HM Stationery Office, London, 1973. Science Research Council Report. 4

[29] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted

windows. In *Proc. of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 2021. 47, 49, 52, 53, 54, 55, 56, 57, 58

[30] Minh-Thang Luong, Hieu Pham, and Christopher D Manning. Effective approaches to attention-based neural machine translation. In *Proc. of EMNLP*, pages 1412–1421, 2015. 24

[31] Andrew McCallum and Kamal Nigam. A comparison of event models for naive bayes text classification. In *AAAI-98 Workshop on Learning for Text Categorization*, pages 41–48, Madison, WI, 1998. 11

[32] John McCarthy, Marvin Minsky, Nathaniel Rochester, and Claude E. Shannon. A proposal for the dartmouth summer research project on artificial intelligence. *Dartmouth College AI Archive*, 1956. 3

[33] Pamela McCorduck. *Machines Who Think: A Personal Inquiry into the History and Prospects of Artificial Intelligence*. A. K. Peters, Ltd., Natick, MA, 2nd edition, 2004. 5

[34] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeffrey Dean. Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems*, pages 3111–3119, 2013. 25, 26

[35] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, New York, 1997. 6, 9, 11

[36] Douglas C. Montgomery, Elizabeth A. Peck, and Geoffrey G. Vining. *Introduction to Linear Regression Analysis*. John Wiley & Sons, Hoboken, NJ, 6th edition, 2021. 8

[37] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. MIT Press, Cambridge, MA, 2012. 6, 7, 8, 9, 10, 11

[38] Makoto Nagao. A framework of a mechanical translation between japanese and english by analogy principle. In *Proc. of the international NATO symposium on artificial and human intelligence*, pages 173–180, 1984. 24

[39] Allen Newell, J. Clifford Shaw, and Herbert A. Simon. Report on a general problem-solving program. In *Proceedings of the International Conference on Information Processing*, pages 256–264, 1959. 4

[40] Nils J. Nilsson. *The Quest for Artificial Intelligence: A History of Ideas and Achievements*. Cambridge University Press, Cambridge, 2010. 4, 5, 6

[41] Jeffrey Pennington, Richard Socher, and Christopher D Manning. Glove: Global vectors for word representation. In *Proc. of EMNLP*, pages 1532–1543, 2014. 25, 26

[42] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training. OpenAI report, 2018. 23

[43] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986. 12, 15, 19

[44] Stuart J. Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, London, 3rd edition, 2016. 5, 6

[45] Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to sequence learning with neural networks. In *Advances in neural information processing systems*, pages 3104–3112, 2014. 24, 37, 38

[46] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2nd edition, 2018. 8

[47] Vladimir Vapnik. *Statistical Learning Theory*. Wiley, New York, 1998. 10

[48] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017. 19, 22, 23, 24, 27, 28, 29, 32, 33, 34, 36, 37, 38, 39, 40, 44, 46, 47

# پیوست آ

# جزئیات مدل‌ها و جدول پارامترها

# Abstract

Recently, graph neural networks (GNNs) have shown success at learning representations of functional brain graphs derived from functional magnetic resonance imaging (fMRI) data.



**Key Words:** Clustering , DBSCAN , Voronoi diagrams , Delaunay triangulation , Outlier detection .

**T. M. U.**

# Vision Trnasformer

A Thesis Presented for the Degree of

Master in Computer Science

Faculty of Mathematical Sciences

**Tarbiat Modares University**

**by**

**Seyed Mohammad Badzohreh**

Supervisor

**Dr. Mansoor Rezghi**

2024